

MAT-468: Sesión 3, Solución de sistemas lineales II

Felipe Osorio

<http://fosorios.mat.utfsm.cl>

Departamento de Matemática, UTFSM



Considere resolver el sistema lineal

$$Ax = b,$$

donde $A \in \mathbb{R}^{n \times n}$ y asumiremos que el sistema admite una **solución exacta** \hat{x} .

A continuación se describe:

- ▶ El método Jacobi.
- ▶ Método Gauss-Seidel.
- ▶ Método de gradientes conjugados.



Para uniformizar la presentación de todos los métodos, sea D , L y U las partes diagonal, triangular inferior y triangular superior de la matriz A , respectivamente¹.

Es decir $D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$, mientras que

$$L = \begin{pmatrix} 0 & 0 & 0 & \dots & 0 \\ a_{21} & 0 & 0 & \dots & 0 \\ a_{31} & a_{32} & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{n,n-1} & 0 \end{pmatrix}, \quad U = \begin{pmatrix} 0 & a_{12} & a_{13} & \dots & a_{1n} \\ 0 & 0 & a_{23} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & & \vdots \\ 0 & 0 & \dots & 0 & a_{n-1,n} \\ 0 & 0 & \dots & 0 & 0 \end{pmatrix}.$$

¹Evidentemente $A = D + L + U$.

Un **método iterativo** para la solución de sistemas lineales construye una secuencia $\{\mathbf{x}^{(k)}\}$, para $k = 0, 1, \dots$, que bajo ciertas condiciones converge a $\hat{\mathbf{x}}$.

$\mathbf{x}^{(0)}$ representa una **estimación inicial** y la secuencia es construída como una **regla** del tipo:

$$\mathbf{x}^{(k+1)} = \mathbf{B}_k \mathbf{x}^{(k)} + \mathbf{C}_k \mathbf{b}, \quad k = 0, 1, \dots, \quad (1)$$

donde $\mathbf{B}_k, \mathbf{C}_k \in \mathbb{R}^{n \times n}$.

Las diferentes elecciones de \mathbf{B}_k y \mathbf{C}_k definen los distintos algoritmos.



La condición básica sobre B_k y C_k que asegura la convergencia del algoritmo es la siguiente:

$$B_k + C_k A = I.$$

En efecto, se debe tener que

$$\hat{x} = B_k \hat{x} + C_k b,$$

y dado que \hat{x} es solución del sistema de ecuaciones $Ax = b$, tenemos

$$\begin{aligned}\hat{x} &= B_k \hat{x} + C_k A \hat{x} \\ &= (B_k + C_k A) \hat{x},\end{aligned}$$

desde donde sigue el resultado.



Resultado 1

Una secuencia $\{x^{(k)}\}$ dada por (1) converge a la solución del sistema $Ax = b$ para cualquier $x^{(0)}$, sólo si

$$\lim_{k \rightarrow \infty} B_k B_{k-1} \cdots B_0 = 0$$

En la práctica se utiliza **métodos iterativos estacionarios**, es decir, tal que $B_k = B$ y $C_k = C$ son constantes. De este modo, tenemos la siguiente regla:

$$x^{(k+1)} = Bx^{(k)} + Cb, \quad k = 0, 1, \dots, \quad (2)$$

y la condición de convergencia en el resultado anterior adopta una forma más simple

Resultado 2

Una secuencia $\{x^{(k)}\}$ dada por (2) converge a la solución del sistema $Ax = b$ para cualquier $x^{(0)}$, si y sólo si el **radio espectral** $\rho(B) < 1$, donde $\rho(B) = \max\{\lambda_1, \dots, \lambda_n\}$ con $\lambda_1, \dots, \lambda_n$ los valores propios de B^2 .

²Esta condición es equivalente a $\|B\| < 1$ para cualquier norma matricial.



Se suele **declarar convergencia** cuando algún criterio preestablecido es satisfecho.

Específicamente, para un nivel de tolerancia τ , el proceso iterativo se detiene si

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| \leq \tau, \quad \|\mathbf{r}^{(k+1)} - \mathbf{r}^{(k)}\| \leq \tau, \quad \text{o} \quad \|\mathbf{r}^{(k+1)}\| \leq \tau,$$

donde $\mathbf{r}^{(k)} = \mathbf{A}\mathbf{x}^{(k)} - \mathbf{b}$ es el **vector residual**.

Además se suele incluir un **número máximo aceptable de iteraciones**.



Suponga que A tiene elementos diagonales no cero. Entonces el sistema $Ax = b$ puede ser escrito como

$$Dx + (L + U)x = b,$$

y de este modo, tenemos que

$$x = D^{-1}[-(L + U)x + b]$$

Esto motiva el siguiente algoritmo:

$$x^{(k+1)} = -D^{-1}(L + U)x^{(k)} + D^{-1}b, \quad k = 0, 1, \dots, \quad (3)$$

Observación:

La condición $\rho(D^{-1}(L + U)) < 1$ es satisfecha para una amplia clase de matrices (por ejemplo, diagonal dominantes, simétricas y definidas positivas).



Análogamente al método Jacobi, podemos reescribir el sistema $Ax = b$ como

$$(L + D)x + Ux = b,$$

es decir

$$x = (L + D)^{-1}[-Ux + b]$$

Esto lleva al esquema iterativo:

$$x^{(k+1)} = -(L + D)^{-1}Ux^{(k)} + (L + D)^{-1}b, \quad k = 0, 1, \dots, \quad (4)$$

Observación:

La condición de convergencia $\rho((L + D)^{-1}U) < 1$ es satisfecha para matrices diagonal dominantes y definidas positivas.



El método Gauss-Seidel puede ser **inaceptablemente lento**. El método de **sobrerelajación sucesiva (SOR)** está basado en la siguiente identidad

$$(D + \omega L)x = -[\omega U + (\omega - 1)D]x + \omega b,$$

donde $\omega > 0$ es llamado **factor de relajación**. Se puede mostrar que SOR converge solamente para valores de $\omega \in (0, 2)$ (ver Kahan, 1958).

De este modo, obtenemos:

$$\begin{aligned} x^{(k+1)} &= (D + \omega L)^{-1}[(\omega - 1)D - \omega U]x^{(k)} + \omega(D + \omega L)^{-1}b, \\ &= M_{\omega}x^{(k)} + d_{\omega}, \quad k = 0, 1, \dots, \end{aligned} \tag{5}$$

Observación:

Una buena elección del parámetro ω^3 puede acelerar la convergencia del método⁴ (Young, 1954; Hadjidimos, 2000).

³ $\omega_{\text{opt}} = 2/(1 + \rho(B))$, con $B = -(L + D)^{-1}U$.

⁴Un radio espectral menor, indica convergencia más rápida



Método de gradientes conjugados

Resolver el sistema lineal $Ax = b$ es equivalente a determinar el **mínimo de la función**:

$$\phi(x) = \frac{1}{2}x^T Ax - x^T b.$$

En efecto, por hacer la derivada de ϕ igual a 0 , vemos que el punto estacionario de ϕ ocurre en el punto x donde $Ax = b$.

- ▶ Este procedimiento asume que la matriz A es **simétrica y definida positiva**.
- ▶ En este caso, el (único) mínimo de ϕ ocurre en $\hat{x} = A^{-1}b$ y es dado por $-\frac{1}{2}b^T A^{-1}b$.

El mínimo puede ser encontrado de forma iterativa, usando el siguiente esquema:

$$x^{(k+1)} = x^{(k)} + \lambda^{(k)} p^{(k)}, \quad r = 0, 1, \dots, \quad (6)$$

donde $\lambda^{(k)}$ es un escalar (que representa un **largo de paso**), mientras que $p^{(k)}$ es un vector que indica la **dirección de búsqueda**.



Método de gradientes conjugados

Resolver el sistema lineal $Ax = b$ es equivalente a determinar el **mínimo de la función**:

$$\phi(x) = \frac{1}{2}x^\top Ax - x^\top b.$$

En efecto, por hacer la derivada de ϕ igual a 0 , vemos que el punto estacionario de ϕ ocurre en el punto x donde $Ax = b$.

- ▶ Este procedimiento asume que la matriz A es **simétrica y definida positiva**.
- ▶ En este caso, el (único) mínimo de ϕ ocurre en $\hat{x} = A^{-1}b$ y es dado por $-\frac{1}{2}b^\top A^{-1}b$.

El mínimo puede ser encontrado de forma iterativa, usando el siguiente esquema:

$$x^{(k+1)} = x^{(k)} + \lambda^{(k)}p^{(k)}, \quad r = 0, 1, \dots, \quad (6)$$

donde $\lambda^{(k)}$ es un escalar (que representa un **largo de paso**), mientras que $p^{(k)}$ es un vector que indica la **dirección de búsqueda**.



Método gradientes conjugados

Note que

$$d_x \phi(\mathbf{x}) = \frac{1}{2} (d\mathbf{x})^\top \mathbf{A} \mathbf{x} - (d\mathbf{x})^\top \mathbf{b} = (d\mathbf{x})^\top (\mathbf{A} \mathbf{x} - \mathbf{b}),$$

es decir,

$$\frac{\partial \phi(\mathbf{x})}{\partial \mathbf{x}} = \mathbf{A} \mathbf{x} - \mathbf{b}, \quad -\frac{\partial \phi(\mathbf{x})}{\partial \mathbf{x}} := \mathbf{r}$$

es un residuo.

Definición 1

Un conjunto de vectores $\{\mathbf{z}_0, \mathbf{z}_1, \dots, \mathbf{z}_k\}$ se dicen **conjugados**⁵ con respecto a la matriz simétrica y definida positiva \mathbf{A} si

$$\mathbf{z}_i^\top \mathbf{A} \mathbf{z}_j = 0, \quad \forall i \neq j.$$

Un conjunto de vectores satisfaciendo esta propiedad también son **linealmente independientes**.

⁵también son dichos \mathbf{A} -conjugados.



Método gradientes conjugados

Ahora, note que

$$\mathbf{x}^{(k)} = \mathbf{x}^{(0)} + \lambda^{(1)}\mathbf{p}^{(1)} + \dots + \lambda^{(k-1)}\mathbf{p}^{(k-1)}.$$

Escogiendo $\lambda^{(k)}$ como

$$\lambda^{(k)} = \frac{\mathbf{r}^{(k)\top} \mathbf{p}^{(k)}}{\mathbf{p}^{(k)\top} \mathbf{A} \mathbf{p}^{(k)}},$$

obtenemos que la dirección de búsqueda $\mathbf{p}^{(k)}$ es \mathbf{A} -conjugada con $\mathbf{p}^{(1)}, \dots, \mathbf{p}^{(k-1)}$.

- ▶ La secuencia $\{\mathbf{x}^{(k)}\}$ definida por el **algoritmo gradiente conjugado** (6) converge a la solución $\hat{\mathbf{x}}$ en a lo más n pasos.
- ▶ El algoritmo puede ser implementado muy eficientemente y por tanto es una opción atractiva para **problemas de gran tamaño**.



Gradientes conjugados

Algoritmo 1: Gradientes conjugados.

Entrada : Estimación inicial $\mathbf{x}^{(0)}$

Parámetros: Tolerancia τ .

```
1 begin
2    $k \leftarrow 0$ 
3   Calcular  $\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(k)}$ ,  $\mathbf{p}^{(k)} = \mathbf{r}^{(k)}$  y  $\gamma^{(k)} = \|\mathbf{r}^{(k)}\|^2$ 
4   while  $\gamma^{(k)} > \tau$  do
5      $\lambda^{(k)} = \frac{\mathbf{r}^{(k)\top} \mathbf{p}^{(k)}}{\mathbf{p}^{(k)\top} \mathbf{A} \mathbf{p}^{(k)}}$ 
6      $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda^{(k)} \mathbf{p}^{(k)}$ 
7      $\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(k+1)}$ 
8      $\beta^{(k)} = \frac{\mathbf{r}^{(k+1)\top} \mathbf{p}^{(k)}}{\mathbf{p}^{(k)\top} \mathbf{A} \mathbf{p}^{(k)}}$ 
9      $\mathbf{p}^{(k+1)} = \mathbf{r}^{(k+1)} - \beta^{(k)} \mathbf{p}^{(k)}$  y  $\gamma^{(k)} = \|\mathbf{r}^{(k)}\|^2$ 
10    Hacer  $k \leftarrow k + 1$  y  $\mathbf{r}^{(k)} \leftarrow \mathbf{r}^{(k+1)}$ ,  $\mathbf{p}^{(k)} \leftarrow \mathbf{p}^{(k+1)}$ 
11  end
12  return  $\hat{\mathbf{x}} = \mathbf{x}^{(k)}$ 
13 end
```

