

MAT-468: Sesión 3, Cálculos en regresión

Felipe Osorio

<http://fosorios.mat.utfsm.cl>

Departamento de Matemática, UTFSM



Antes de describir una variante para obtener la [descomposición ortogonal-triangular \(QR\)](#) de una matriz es conveniente revisar algunas propiedades fundamentales de las matrices ortogonales:

- ▶ $QQ^T = Q^T Q = I$.
- ▶ $\langle Qx, Qy \rangle = x^T Q^T Q y = x^T y = \langle x, y \rangle$.
- ▶ $\|Qx\| = \|x\|$.
- ▶ Si $B = Q^T A Q$, entonces A y B tienen los mismos valores propios para Q matriz ortogonal.

Existen diversas variantes del algoritmo para implementar la [descomposición QR](#). A continuación veremos una basada en [transformaciones Householder](#).



Problema 1

Para $\mathbf{x} \in \mathbb{R}^p$, $\mathbf{x} \neq \mathbf{0}$, hallar una **matriz ortogonal** $\mathbf{M} \in \mathbb{R}^{p \times p}$ tal que

$$\mathbf{M}^\top \mathbf{x} = \|\mathbf{x}\| \mathbf{e}_1,$$

donde $\mathbf{e}_1 = (1, 0, \dots, 0)^\top$ denota el primer **vector unidad**.

Definición 1 (Reflexión)

Sea \mathbf{u} y \mathbf{v} **vectores ortonormales** y \mathbf{x} vector generado por \mathbf{u} y \mathbf{v} . Entonces

$$\mathbf{x} = c_1 \mathbf{u} + c_2 \mathbf{v},$$

para escalares c_1, c_2 . El vector

$$\tilde{\mathbf{x}} = -c_1 \mathbf{u} + c_2 \mathbf{v},$$

el llamado una **reflexión** de \mathbf{x} a través de la línea definida por el vector \mathbf{v} (o \mathbf{u}^\perp).



Definición 2 (Transformación Householder)

Sea $\mathbf{x} = c_1\mathbf{u} + c_2\mathbf{v}$, con \mathbf{u} y \mathbf{v} vectores generadores de \mathbf{x} y considere la matriz

$$\mathbf{H} = \mathbf{I} - \lambda \mathbf{u} \mathbf{u}^\top, \quad \lambda = 2/\mathbf{u}^\top \mathbf{u}.$$

Note que $\mathbf{H}\mathbf{x} = \tilde{\mathbf{x}}$, es decir \mathbf{H} es un reflector.

La [transformación Householder](#) satisface las siguientes propiedades:

- ▶ $\mathbf{H}\mathbf{u} = -\mathbf{u}$.
- ▶ $\mathbf{H}\mathbf{v} = \mathbf{v}$ para cualquier \mathbf{v} ortogonal a \mathbf{u} .
- ▶ $\mathbf{H}^\top = \mathbf{H}$.
- ▶ $\mathbf{H}^{-1} = \mathbf{H}^\top$.



Considere $\mathbf{u} = \mathbf{x} + \delta \mathbf{e}_1$, donde $\delta^2 = \mathbf{x}^\top \mathbf{x}$. Es fácil notar que,

$$\begin{aligned}\mathbf{u}^\top \mathbf{u} &= (\mathbf{x} + \delta \mathbf{e}_1)^\top (\mathbf{x} + \delta \mathbf{e}_1) = \mathbf{x}^\top \mathbf{x} + 2\delta \mathbf{x}^\top \mathbf{e}_1 + \delta^2 \mathbf{e}_1^\top \mathbf{e}_1 \\ &= \delta^2 + 2\delta x_1 + \delta^2 = 2(\delta^2 + \delta x_1),\end{aligned}$$

así

$$\lambda = \frac{2}{\|\mathbf{u}\|^2} = \frac{1}{\delta^2 + \delta x_1}.$$

Además,

$$\mathbf{u}^\top \mathbf{x} = (\mathbf{x} + \delta \mathbf{e}_1)^\top \mathbf{x} = \mathbf{x}^\top \mathbf{x} + \delta \mathbf{e}_1^\top \mathbf{x} = \delta^2 + \delta x_1.$$

De este modo, \mathbf{H} satisface:¹

$$\begin{aligned}\mathbf{H}\mathbf{x} &= (\mathbf{I} - \lambda \mathbf{u} \mathbf{u}^\top) \mathbf{x} = \mathbf{x} - \lambda (\mathbf{u}^\top \mathbf{x}) \mathbf{u} \\ &= \mathbf{x} - \lambda (\delta^2 + \delta x_1) (\mathbf{x} + \delta \mathbf{e}_1) = \mathbf{x} - \mathbf{x} - \delta \mathbf{e}_1 \\ &= -\delta \mathbf{e}_1.\end{aligned}$$

¹Note que $\mathbf{H}\mathbf{x}$ puede ser obtenido usando un `axpy`.

La **descomposición QR** de una matriz $A \in \mathbb{R}^{n \times p}$ ($n > p$), puede ser construída a través de una **secuencia de matrices** Q_1, \dots, Q_p tales que

$$Q_p \cdots Q_1 A = \begin{pmatrix} R \\ 0 \end{pmatrix},$$

donde **todas** Q_1, \dots, Q_p son ortogonales. De este modo,

$$A = Q_1^\top \cdots Q_p^\top \begin{pmatrix} R \\ 0 \end{pmatrix} = Q \begin{pmatrix} R \\ 0 \end{pmatrix}.$$

A continuación se describe el algoritmo para obtener la **descomposición QR** usando **transformaciones Householder**.² Sea $M(x)$ la matriz ortogonal desde el **Problema 1** basada en un vector x .

²Otro método popular para obtener la descomposición QR es usando rotaciones Givens.



Algoritmo 1: Descomposición QR

Entrada: Matriz $A \in \mathbb{R}^{n \times p}$.

Salida : Factores Q y R , matrices ortogonal y triangular superior, respectivamente.

```
1 begin
2   Hacer  $Q = I_n$  y  $R = A$ 
3   for  $i = 1$  to  $p$  do
4      $x = (R_{1i}, \dots, R_{pi})^\top$ 
5      $Q_i = \begin{pmatrix} I_{i-1} & 0 \\ 0 & M(x) \end{pmatrix}$ 
6     /*  $M(x)$  obtenido usando reflexiones Householder */
7      $Q = Q_i Q$ 
8      $R = Q_i R$ 
9   end
10   $Q = Q^\top$ 
11   $R = (R_{ij})$  para  $i, j = 1, \dots, p$ .
12 end
```



Aplicación en regresión lineal

Sea el **modelo de regresión lineal**:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon},$$

donde $\mathbf{X} \in \mathbb{R}^{n \times p}$ con $\text{rg}(\mathbf{X}) = p$ y $E(\boldsymbol{\epsilon}) = \mathbf{0}$ y $\text{Cov}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{I}$. El **estimador mínimos cuadrados (LS)** de $\boldsymbol{\beta}$ es:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}, \quad \text{con} \quad \text{Cov}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}.$$

Además,

$$s^2 = \frac{1}{n-p} \|\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|^2.$$

Adicionalmente, si $\boldsymbol{\epsilon} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I})$, entonces³

$$\begin{aligned} \hat{\boldsymbol{\beta}} &\sim N_p(\boldsymbol{\beta}, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}), \\ \frac{(n-p)s^2}{\sigma^2} &\sim \chi^2(n-p). \end{aligned}$$

³En cuyo caso, $\hat{\boldsymbol{\beta}}$ corresponde al estimador ML de $\boldsymbol{\beta}$.



Las ecuaciones de estimación para obtener $\hat{\beta}$ son $\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\hat{\beta}) = \mathbf{0}$, o bien

$$\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{Y}. \quad (1)$$

Así, podemos resolver (1) usando la [descomposición Cholesky](#), de

$$\mathbf{X}^\top \mathbf{X} = \mathbf{U}^\top \mathbf{U},$$

con \mathbf{U} matrix triangular superior. De este modo:

$$\mathbf{U}^\top \mathbf{z} = \mathbf{X}^\top \mathbf{Y}, \quad \text{y} \quad \mathbf{U} \hat{\beta} = \mathbf{z},$$

para obtener s^2 considere

$$RSS = \|\mathbf{Y} - \mathbf{X}\hat{\beta}\|^2 = \mathbf{Y}^\top \mathbf{Y} - \mathbf{z}^\top \mathbf{z}.$$

Invirtiendo \mathbf{U} (in-place)⁴, podemos hacer

$$\mathbf{U}^{-1} \mathbf{U}^{-\top} = (\mathbf{X}^\top \mathbf{X})^{-1}.$$

⁴Haciendo $\mathbf{U} \leftarrow \mathbf{U}^{-1}$, tenemos $(\mathbf{X}^\top \mathbf{X})^{-1} = \mathbf{U} \mathbf{U}^\top$

Aplicación en regresión lineal

Considere

$$\mathbf{Z} = (\mathbf{X}, \mathbf{Y}) \in \mathbb{R}^{n \times (p+1)},$$

luego

$$\mathbf{Z}^\top \mathbf{Z} = \begin{pmatrix} \mathbf{X}^\top \mathbf{X} & \mathbf{X}^\top \mathbf{Y} \\ \mathbf{Y}^\top \mathbf{X} & \mathbf{Y}^\top \mathbf{Y} \end{pmatrix} \in \mathbb{R}^{(p+1) \times (p+1)}.$$

Aplicando el **operador Sweep** sobre los **primeros** p elementos diagonales de $\mathbf{Z}^\top \mathbf{Z}$, obtenemos:

$$\begin{aligned} \mathbf{B} &= \prod_{i=1}^p \text{Sweep}(i) \mathbf{Z}^\top \mathbf{Z} \\ &= \begin{pmatrix} (\mathbf{X}^\top \mathbf{X})^{-1} & (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \\ -\mathbf{Y}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} & \mathbf{Y}^\top \mathbf{Y} - \mathbf{Y}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \end{pmatrix} \\ &= \begin{pmatrix} (\mathbf{X}^\top \mathbf{X})^{-1} & \hat{\boldsymbol{\beta}} \\ \hat{\boldsymbol{\beta}}^\top & RSS \end{pmatrix}. \end{aligned}$$



Considere la **descomposición QR** (Ortogonal-Triangular) de X , como:

$$X = QR, \quad R = \begin{pmatrix} R_1 \\ 0 \end{pmatrix}$$

con $R_1 \in \mathbb{R}^{p \times p}$ matriz triangular superior ($n > p$). Si $\text{rg}(X) = p$, entonces R_1 es no singular. Además, considere la transformación:

$$Q^T Y = c, \quad c = (c_1^T, c_2^T)^T.$$

El **estimador LS** minimiza la función objetivo:

$$\begin{aligned} \|Y - X\beta\|^2 &= \|Q^T(Y - X\beta)\|^2 = \|Q^T Y - Q^T QR\beta\|^2 \\ &= \|c - R\beta\|^2, \end{aligned}$$

Es fácil notar que:

$$\|c - R\beta\|^2 = \|c_1 - R_1\beta\|^2 + \|c_2\|^2.$$



Finalmente, el **estimador de mínimos cuadrados** $\hat{\beta}$ está dado por la solución del sistema triangular:

$$R_1 \hat{\beta} = c_1.$$

El mínimo de la función objetivo está dado por $\|c_2\|^2$. Note además que

$$\hat{\sigma}^2 = \frac{1}{n} \|c_2\|^2,$$

corresponde al estimador máximo verosímil para σ^2 .⁵ Por otro lado,

$$R_1^{-1} R_1^{-\top} = (X^\top X)^{-1},$$

permite obtener $\text{Cov}(\hat{\beta})$.

⁵bajo el supuesto de normalidad.



Considere la **descomposición valor singular (SVD)** de X ,

$$X = UDV^{\top},$$

donde $U \in \mathbb{R}^{n \times p}$ tal que $U^{\top}U = I_p$, $D = \text{diag}(d_1, \dots, d_p)$ y V es matriz ortogonal $p \times p$. De este modo, podemos escribir el modelo:

$$Y = X\beta + \epsilon = UD\alpha + \epsilon,$$

con $\alpha = V^{\top}\beta$. Haciendo $Z = U^{\top}Y$, tenemos el modelo en **forma canónica**:

$$Z = D\alpha + \delta, \quad \delta = U^{\top}\epsilon,$$

donde $E(\delta) = \mathbf{0}$ y $\text{Cov}(\delta) = \sigma^2 U^{\top}U = \sigma^2 I_p$.



El **estimador LS** de α en el modelo canónico es:

$$\hat{\alpha} = D^{-1}Z, \quad \Rightarrow \quad \hat{\beta} = V\hat{\alpha}.$$

Además,

$$\|Y - X\hat{\beta}\|^2 = \|Y - UDV^T\hat{\beta}\|^2 = \|Z - D\hat{\alpha}\|^2.$$

Finalmente,

$$(X^T X)^{-1} = (VD^2V^T)^{-1} = VD^{-2}V^T.$$

