

MAT-468: Modelos de regresión para datos agrupados

Felipe Osorio

fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM





Davidian, M., and Giltinan, D. M. (1995).
Nonlinear Models for Repeated Measurement Data.
Chapman & Hall, London.



Pinheiro, J. C., and Bates, D. M. (2000).
Mixed-Effects Models in S and S-Plus.
Springer, New York.



Vonesh, E. F., and Chinchilli, V. M. (1997).
Linear and Nonlinear Models for the Analysis of Repeated Measurements.
Marcel Dekker, New York.


Definición 1 (medidas repetidas):

Datos repetidos surgen cuando una respuesta es medida repetidamente en un conjunto de unidades.

- ▶ Unidades.
 - ▶ Individuos, pacientes,
 - ▶ Animales, plantas,
 - ▶ Familias, ciudades, industrias, ...
- ▶ Caso especial: **Datos longitudinales**.



Estudio de Ortodoncia (Potthoff y Roy, 1964)



Objetivo:


- ▶ Investigar el patrón de crecimiento dental.
- ▶ Estudiar diferencias significativas entre ambos grupos.

Observaciones:

- ▶ Bastante variabilidad entre individuos con menor variabilidad dentro de individuos (especialmente en grupo femenino).
- ▶ Igual número de mediciones por individuo (**datos balanceados**).
- ▶ Mediciones tomadas en instantes fijos.
- ▶ Algunos datos con crecimiento atípico.



Estudio reproductivo en roedores (Dempster et al., 1984)




Observaciones:

- ▶ Datos altamente desbalanceados.
- ▶ Comportamiento similar por tratamiento.
- ▶ Gran variabilidad dentro de algunos grupos (nidadas).
- ▶ Algunas crías con peso "atípico" (Rosa, Padovani y Gianola, 2003).



Crecimiento de plantas de Soya (Davidian y Giltinan, 1995)




Observaciones:

- ▶ Estudio típico en **Agricultura, Genética** con observaciones ligeramente desbalanceadas.
- ▶ Relación **no lineal** entre peso y tiempo.
- ▶ **Modelo logístico** usualmente utilizado para explicar el crecimiento

$$Y = \frac{\beta_1}{1 + \beta_2 \exp(\beta_3 x)}, \quad \beta_1, \beta_2 > 0, \beta_3 < 0.$$



Cinética de Teofilina (Boeckmann, Sheiner y Beal, 1984)



Observaciones:

- ▶ Estudio de laboratorio (farmacocinética) con pocos individuos y varias observaciones balanceadas.
- ▶ Modelo mecánico: modelo de primer orden de un compartimento.

$$C_t = \frac{\Delta K k_a}{Cl(k_a - K)} [\exp(-Kt) - \exp(-k_a t)].$$

donde Δ es la dosis inicial, k_a tasa de absorción, K tasa de eliminación, Cl clearance.



Definición 1 (Modelo GMANOVA)

Un modelo GMANOVA (curvas de crecimiento) está definido como

$$Y = XBZ + E,$$

donde $X \in \mathbb{R}^{n \times m}$ y $Z \in \mathbb{R}^{q \times p}$ son matrices de diseño con $\text{rg}(X) = m$ y $\text{rg}(Z) = q$, respectivamente. $B \in \mathbb{R}^{q \times r}$ es matriz de coeficientes de regresión y

$$E \sim N_{n,p}(\mathbf{0}, I_n, \Sigma).$$

De ahí que

$$Y \sim N_{n,p}(XBZ, I_n, \Sigma).$$



Considere

$$Q(B) = (Y - XBZ)^{\top}(Y - XBZ).$$

El **estimador LS** en el modelo GMANOVA está definido como la solución del problema:

$$\min_B \operatorname{tr} Q(B) := \min_B \operatorname{tr} (Y - XBZ)^{\top}(Y - XBZ).$$

En efecto, diferenciando con relación a B , obtenemos

$$\begin{aligned} d_B \operatorname{tr} Q(B) &= -\operatorname{tr} Z^{\top}(dB)^{\top} X^{\top}(Y - XBZ) - \operatorname{tr} (Y - XBZ)^{\top} X(dB)Z \\ &= -2\operatorname{tr} X^{\top}(Y - XBZ)Z^{\top}(dB)^{\top}, \end{aligned}$$

de ahí que la **ecuación de estimación para B** es dada por:

$$X^{\top}(Y - XBZ)Z^{\top} = 0.$$



Desde la ecuación de estimación $\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\mathbf{B}\mathbf{Z})\mathbf{Z}^\top = \mathbf{0}$, tenemos que

$$\mathbf{X}^\top \mathbf{X} \hat{\mathbf{B}} \mathbf{Z} \mathbf{Z}^\top = \mathbf{X}^\top \mathbf{Y} \mathbf{Z}^\top,$$

es decir el **estimador LS para \mathbf{B}** asume la forma:

$$\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \mathbf{Z}^\top (\mathbf{Z} \mathbf{Z}^\top)^{-1}.$$

Por otro lado,

$$\begin{aligned} d_B^2 \operatorname{tr} \mathbf{Q}(\mathbf{B}) &= 2 \operatorname{tr} \mathbf{X}^\top \mathbf{X} (\mathrm{d}\mathbf{B}) \mathbf{Z} \mathbf{Z}^\top (\mathrm{d}\mathbf{B})^\top \\ &= 2 (\mathrm{d} \operatorname{vec} \mathbf{B})^\top (\mathbf{Z} \mathbf{Z}^\top \otimes \mathbf{X}^\top \mathbf{X}) \mathrm{d} \operatorname{vec} \mathbf{B}, \end{aligned}$$

y como $\mathbf{Z} \mathbf{Z}^\top \otimes \mathbf{X}^\top \mathbf{X}$ es matriz positiva definida, sigue que $\hat{\mathbf{B}}$ es **mínimo (global)**.



Para el ejemplo de **datos dentales** tenemos que:

$$\mathbf{X} = \begin{pmatrix} \mathbf{1}_{16} & \mathbf{0} \\ \mathbf{0} & \mathbf{1}_{11} \end{pmatrix}, \quad \mathbf{Z} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 8 & 10 & 12 & 14 \end{pmatrix},$$

mientras que $\mathbf{Y} \in \mathbb{R}^{27 \times 4}$. De este modo, tenemos que $\mathbf{B} \in \mathbb{R}^{2 \times 2}$ y $\mathbf{\Sigma}$ es matriz definida positiva 4×4 .



Comandos en R

```
1 library(nlme) # Biblioteca nlme contiene los datos 'dentales'
2 data(Orthodont)
3 names(Orthodont)
4 [1] "distance" "age"           "Subject"  "Sex"
5
6 # matriz de respuestas
7 y <- Orthodont$distance
8 y <- matrix(y, ncol = 4, byrow = TRUE)
9
10 y
11      [,1] [,2] [,3] [,4]
12 [1,] 26.0 25.0 29.0 31.0
13 [2,] 21.5 22.5 23.0 26.5
14 [3,] 23.0 22.5 24.0 27.5
15 [4,] 25.5 27.5 26.5 27.0
16
17 ...
18
19 [24,] 23.0 23.0 23.5 24.0
20 [25,] 20.0 21.0 22.0 21.5
21 [26,] 16.5 19.0 19.0 19.5
22 [27,] 24.5 25.0 28.0 28.0
```



Comandos en R

```
1 # matrices de disenno
2 x <- cbind(c(rep(1,16), rep(0,11)), c(rep(0,16), rep(1,11)))
3 z <- rbind(rep(1,4), c(8,10,12,14))
4
5 # contruye estimador para B
6 xx <- crossprod(x)
7 zz <- crossprod(t(z))
8 xyz <- crossprod(x, y %*% t(z))
9 B <- solve(xx, xyz %*% solve(zz))
10
11 # Salida
12 B
13      Intercept      age
14 Male      16.34063 0.7843750
15 Female    17.37273 0.4795455
```



Comandos en R

```
1 # construye estimador para Sigma
2 res <- y - x %*% B %*% z
3 n <- nrow(y)
4 Sigma <- crossprod(res) / n
5
6 # Salida
7 Sigma
8           [,1]      [,2]      [,3]      [,4]
9 [1,] 5.054480 2.457757 3.615701 2.531994
10 [2,] 2.457757 3.958162 2.717032 3.039186
11 [3,] 3.615701 2.717032 5.978775 3.821699
12 [4,] 2.531994 3.039186 3.821699 4.629217
13
14 # Calcula covarianza (estimada) del estimador de B
15 kronecker(solve(xx), solve(zz, z %*% Sigma %*% t(z)) %*% solve(zz))
16           [,1]      [,2]      [,3]      [,4]
17 [1,] 0.96056230 -0.071385371 0.00000000 0.00000000
18 [2,] -0.07138537 0.006848071 0.00000000 0.00000000
19 [3,] 0.00000000 0.000000000 1.3971815 -0.10383327
20 [4,] 0.00000000 0.000000000 -0.1038333 0.00996083
```



- ▶ Primeramente, asumiremos que la matriz Σ es **no estructurada**, es decir corresponde a una **matriz simétrica y definida positiva**.
- ▶ Luego consideraremos **estructuras lineales** del tipo:

$$\Sigma = Z^{\top} \Gamma Z + G^{\top} \Phi G,$$

donde $G \in \mathcal{Q}$ tal que

$$\mathcal{Q} = \{G : G \in \mathbb{R}^{p \times (p-m)}, GZ^{\top} = 0\}.$$

Clase que es conocida como **estructura de covarianza (simple) de Rao**.



Sea $\Theta = (B, \Sigma)$, entonces la **función de log-verosimilitud** adopta la forma

$$\begin{aligned}\ell(\Theta) &= \log \left\{ (2\pi)^{-np/2} |\Sigma|^{-n/2} \exp \left\{ -\frac{1}{2} \text{tr} \Sigma^{-1} Q(B) \right\} \right\} \\ &= -\frac{np}{2} \log 2\pi - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \text{tr} \Sigma^{-1} Q(B),\end{aligned}$$

donde

$$Q(B) = (Y - XBZ)^{\top} (Y - XBZ),$$

corresponde a la matriz de **suma de productos cruzados** (de errores).



Diferenciando con relación a B , obtenemos:

$$d_B \ell(\Theta) = -\frac{1}{2} \text{tr } \Sigma^{-1} d_B Q(B),$$

por otro lado,

$$d_B Q(\Theta) = -\text{tr} \left\{ (Y - XBZ)^\top X (dB) Z + Z^\top (dB)^\top X^\top (Y - XBZ) \right\},$$

De este modo, recordando que $\text{tr } A = \text{tr } A^\top$, obtenemos

$$d_B \ell(\Theta) = \text{tr } Z \Sigma^{-1} (Y - XBZ)^\top X dB.$$

Por tanto, la **ecuación de estimación para B** (obtenida desde $d_B \ell(\Theta) = 0$) asume la forma:

$$X^\top (Y - XBZ) \Sigma^{-1} Z^\top = 0,$$



Ahora, diferenciando con relación a Σ , obtenemos:

$$\begin{aligned}d_{\Sigma} \ell(\Theta) &= -\frac{n}{2} \operatorname{tr} \Sigma^{-1} d\Sigma + \frac{1}{2} \operatorname{tr} \Sigma^{-1} (d\Sigma) \Sigma^{-1} Q(B) \\&= -\frac{n}{2} \operatorname{tr} \Sigma^{-1} \left(\Sigma - \frac{1}{n} Q(B) \right) \Sigma^{-1} d\Sigma.\end{aligned}$$

De este modo, la ecuación de estimación para Σ es dada por:

$$n\Sigma - Q(B) = 0.$$



Por tanto, los MLEs de B y Σ deben satisfacer el siguiente sistema de ecuaciones:

$$\begin{aligned} X^{\top}(Y - XBZ)\hat{\Sigma}^{-1}Z^{\top} &= 0 \\ n\hat{\Sigma} - Q(\hat{B}) &= 0. \end{aligned} \tag{1}$$

El siguiente resultado, presenta la solución $(\hat{B}, \hat{\Sigma})$ para las ecuaciones de verosimilitud anteriores.

Resultado 1 (MLE-UN en GMANOVA)

Para el modelo GMANOVA con matrices de diseño X , Z de rango completo. Se tiene que la [solución de la ecuación de verosimilitud en \(1\)](#) es única y es dada por

$$\hat{B} = (X^{\top}X)^{-1}X^{\top}YS^{-1}Z^{\top}(ZS^{-1}Z^{\top})^{-1},$$

y

$$\hat{\Sigma} = \frac{1}{n}(Y - X\hat{B}Z)^{\top}(Y - X\hat{B}Z)$$

donde $S = Y^{\top}(I - H_X)Y$ y $H_X = X(X^{\top}X)^{-1}X$.



```
1 ## Supondremos que los datos 'x', 'y', 'z' estan cargados en
2 ## nuestro directorio de trabajo.
3
4 # calculos en el modelo de regresion multivariado
5 xy <- crossprod(x, y)
6 r <- y - x %*% solve(xx, xy)
7 S <- crossprod(r)
8
9 # Salida
10 S
11           [,1]      [,2]      [,3]      [,4]
12 [1,] 135.38636   67.92045   97.75568   67.75568
13 [2,]  67.92045 104.61932   73.17898   82.92898
14 [3,]  97.75568   73.17898 161.39347 103.26847
15 [4,]  67.75568   82.92898 103.26847 124.64347
```


Comandos en R

```
1 # construye estimador para B
2 zsz <- z %>% solve(S, t(z))
3 rhs <- solve(S, t(z) %>% solve(zsz))
4 B <- solve(xx, xy) %>% rhs
5
6 # Salida
7 B
8           Intercept           age
9 Male      15.84229  0.8268033
10 Female   17.42537  0.4763647
11
12 # construye estimador para Sigma
13 res <- y - x %>% B %>% z
14 n <- nrow(y)
15 Sigma <- crossprod(res) / n
16
17 # Salida
18 Sigma
19           [,1]      [,2]      [,3]      [,4]
20 [1,]  5.119199  2.440902  3.610510  2.522243
21 [2,]  2.440902  3.927948  2.717514  3.062349
22 [3,]  3.610510  2.717514  5.979798  3.823461
23 [4,]  2.522243  3.062349  3.823461  4.617984
```



¿Existe alguna condición en la que el **estimador ML** bajo el modelo GMANOVA

$$\hat{B}_S = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \mathbf{S}^{-1} \mathbf{Z}^\top (\mathbf{Z} \mathbf{S}^{-1} \mathbf{Z}^\top)^{-1},$$

coincida con el **estimador LS**?

$$\hat{B} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \mathbf{Z}^\top (\mathbf{Z} \mathbf{Z}^\top)^{-1},$$

Observación:

La respuesta a la pregunta anterior puede ser resuelto mediante **modelar la estructura de covarianza**.



Definición 2 (Estructura de covarianza simple de Rao)

La estructura de **covarianza simple de Rao (SCS)** es dada por

$$\Sigma = \mathbf{Z}^\top \mathbf{\Gamma} \mathbf{Z} + \mathbf{G}^\top \mathbf{\Phi} \mathbf{G},$$

donde $\mathbf{Z} \in \mathbb{R}^{q \times p}$ ($\text{rg}(\mathbf{Z}) = q$) y $\mathbf{G} \in \mathcal{Q}$, con

$$\mathcal{G} = \{\mathbf{G} : \mathbf{G} \in \mathbb{R}^{p \times (p-q)}, \mathbf{G}\mathbf{Z}^\top = \mathbf{0} = \mathbf{Z}\mathbf{G}^\top\}.$$



Resultado 2 (MLE-SCS en GMANOVA)

Para el modelo GMANOVA con *estructura de covarianza simple de Rao*, los estimadores ML pueden ser expresados como:

$$\hat{B} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \mathbf{Z}^\top (\mathbf{Z} \mathbf{Z}^\top)^{-1}$$

$$\hat{\Gamma} = \frac{1}{n} (\mathbf{Z} \mathbf{Z}^\top)^{-1} \mathbf{Z} \mathbf{S} \mathbf{Z}^\top (\mathbf{Z} \mathbf{Z}^\top)^{-1}$$

$$\hat{\Phi} = \frac{1}{n} (\mathbf{G} \mathbf{G}^\top)^{-1} \mathbf{G} \mathbf{Y}^\top \mathbf{Y} \mathbf{G}^\top (\mathbf{G} \mathbf{G}^\top)^{-1}.$$



Estimación ML de los componentes de Σ en GMANOVA

Sea

$$\tilde{Z} = \begin{pmatrix} Z \\ G \end{pmatrix}.$$

Note que $\Sigma = |Z^T \Gamma Z + G^T \Phi G|$, puede ser escrito como

$$\begin{aligned} |\Sigma| &= \left| (Z^T, G^T) \begin{pmatrix} \Gamma & 0 \\ 0 & \Phi \end{pmatrix} \begin{pmatrix} Z \\ G \end{pmatrix} \right| = \left| \begin{pmatrix} Z \\ G \end{pmatrix} (Z^T, G^T) \begin{pmatrix} \Gamma & 0 \\ 0 & \Phi \end{pmatrix} \right| \\ &= \left| \begin{matrix} ZZ^T & 0 \\ 0 & GG^T \end{matrix} \right| \left| \begin{matrix} \Gamma & 0 \\ 0 & \Phi \end{matrix} \right| = |ZZ^T| |GG^T| |\Gamma| |\Phi|. \end{aligned}$$

Por otro lado,

$$\begin{aligned} \Sigma^{-1} &= \begin{pmatrix} Z \\ G \end{pmatrix}^{-1} \begin{pmatrix} \Gamma^{-1} & 0 \\ 0 & \Phi^{-1} \end{pmatrix} (Z^T, G^T)^{-1} \\ &= (Z^T (ZZ^T)^{-1}, G^T (GG^T)^{-1}) \begin{pmatrix} \Gamma^{-1} & 0 \\ 0 & \Phi^{-1} \end{pmatrix} \begin{pmatrix} (ZZ^T)^{-1} Z \\ (GG^T)^{-1} G \end{pmatrix} \\ &= Z^T (ZZ^T)^{-1} \Gamma^{-1} (ZZ^T)^{-1} Z + G^T (GG^T)^{-1} \Phi^{-1} (GG^T)^{-1} G \end{aligned}$$



Considere $\Theta = (B, \Gamma, \Phi)$, entonces la **función de log-verosimilitud** es dada por

$$\begin{aligned}\ell(\Theta) &= \log \left\{ (2\pi)^{-np/2} |\Sigma|^{-n/2} \exp \left\{ -\frac{1}{2} \text{tr} \Sigma^{-1} Q(B) \right\} \right\} \\ &= -\frac{np}{2} \log 2\pi - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \text{tr} \Sigma^{-1} Q(B),\end{aligned}$$

donde

$$Q(B) = (Y - XBZ)^{\top} (Y - XBZ).$$



Note que

$$\log |\Sigma| = \log |\mathbf{Z}\mathbf{Z}^\top| + \log |\mathbf{G}\mathbf{G}^\top| + \log |\mathbf{\Gamma}| + \log |\mathbf{\Phi}|.$$

Por otro lado,

$$\begin{aligned}\text{tr } \Sigma^{-1} \mathbf{Q}(\mathbf{B}) &= \text{tr } \mathbf{Z}^\top (\mathbf{Z}\mathbf{Z}^\top)^{-1} \mathbf{\Gamma}^{-1} (\mathbf{Z}\mathbf{Z}^\top)^{-1} \mathbf{Z} \mathbf{Q}(\mathbf{B}) \\ &\quad + \text{tr } \mathbf{G}^\top (\mathbf{G}\mathbf{G}^\top)^{-1} \mathbf{\Phi}^{-1} (\mathbf{G}\mathbf{G}^\top)^{-1} \mathbf{G} \mathbf{Q}(\mathbf{B}) \\ &= \text{tr } \mathbf{\Gamma}^{-1} (\mathbf{Y}\mathbf{Z}^\top (\mathbf{Z}\mathbf{Z}^\top)^{-1} - \mathbf{X}\mathbf{B})^\top (\mathbf{Y}\mathbf{Z}^\top (\mathbf{Z}\mathbf{Z}^\top)^{-1} - \mathbf{X}\mathbf{B}) \\ &\quad + \text{tr } \mathbf{\Phi}^{-1} (\mathbf{G}\mathbf{G}^\top)^{-1} \mathbf{G} \mathbf{Y}^\top \mathbf{Y} \mathbf{G}^\top (\mathbf{G}\mathbf{G}^\top)^{-1}\end{aligned}$$



Finalmente, la **función de log-verosimilitud** para $\Theta = (B, \Gamma, \Phi)$ asume la forma

$$\begin{aligned}\ell(\Theta) = & -\frac{np}{2} \log 2\pi - \frac{n}{2} \log |\mathbf{Z}\mathbf{Z}^\top| - \frac{n}{2} \log |\mathbf{G}\mathbf{G}^\top| \\ & - \frac{n}{2} \log |\mathbf{\Gamma}| - \frac{1}{2} \text{tr} \mathbf{\Gamma}^{-1} (\mathbf{Y}\mathbf{Z}^\top (\mathbf{Z}\mathbf{Z}^\top)^{-1} - \mathbf{X}\mathbf{B})^\top (\mathbf{Y}\mathbf{Z}^\top (\mathbf{Z}\mathbf{Z}^\top)^{-1} - \mathbf{X}\mathbf{B}) \\ & - \frac{n}{2} \log |\mathbf{\Phi}| - \frac{1}{2} \text{tr} \mathbf{\Phi}^{-1} (\mathbf{G}\mathbf{G}^\top)^{-1} \mathbf{G}\mathbf{Y}^\top \mathbf{Y}\mathbf{G}^\top (\mathbf{G}\mathbf{G}^\top)^{-1}.\end{aligned}$$



De este modo, **diferenciando con relación a Γ** , obtenemos:

$$\begin{aligned}d_{\Gamma} \ell(\Theta) &= -\frac{n}{2} \operatorname{tr} \Gamma^{-1} d\Gamma \\&\quad + \frac{1}{2} \operatorname{tr} \Gamma^{-1} (d\Gamma) \Gamma^{-1} (\mathbf{Y} \mathbf{Z}^{\top} (\mathbf{Z} \mathbf{Z}^{\top})^{-1} - \mathbf{X} \mathbf{B})^{\top} (\mathbf{Y} \mathbf{Z}^{\top} (\mathbf{Z} \mathbf{Z}^{\top})^{-1} - \mathbf{X} \mathbf{B}) \\&= -\frac{n}{2} \operatorname{tr} \Gamma^{-1} \left\{ \Gamma - \frac{1}{n} (\mathbf{Y} \mathbf{Z}^{\top} (\mathbf{Z} \mathbf{Z}^{\top})^{-1} - \mathbf{X} \mathbf{B})^{\top} (\mathbf{Y} \mathbf{Z}^{\top} (\mathbf{Z} \mathbf{Z}^{\top})^{-1} - \mathbf{X} \mathbf{B}) \right\} \Gamma^{-1} d\Gamma.\end{aligned}$$

Por tanto el **estimador ML para Γ** es dado por:

$$\begin{aligned}\hat{\Gamma} &= \frac{1}{n} (\mathbf{Y} \mathbf{Z}^{\top} (\mathbf{Z} \mathbf{Z}^{\top})^{-1} - \mathbf{X} \hat{\mathbf{B}})^{\top} (\mathbf{Y} \mathbf{Z}^{\top} (\mathbf{Z} \mathbf{Z}^{\top})^{-1} - \mathbf{X} \hat{\mathbf{B}}) \\&= \frac{1}{n} (\mathbf{Z} \mathbf{Z}^{\top})^{-1} \mathbf{Z} \mathbf{S} \mathbf{Z}^{\top} (\mathbf{Z} \mathbf{Z}^{\top})^{-1}\end{aligned}$$



De este modo, diferenciando con relación a Φ , obtenemos:

$$\begin{aligned}d_{\Phi} \ell(\Theta) &= -\frac{n}{2} \text{tr} \Phi^{-1} d\Phi + \frac{1}{2} \text{tr} \Phi^{-1} (d\Phi) \Phi^{-1} (GG^{\top})^{-1} GY^{\top} YG^{\top} (GG^{\top})^{-1} \\&= -\frac{n}{2} \text{tr} \Phi^{-1} \left\{ \Phi - \frac{1}{n} (GG^{\top})^{-1} GY^{\top} YG^{\top} (GG^{\top})^{-1} \right\} \Phi^{-1} d\Phi.\end{aligned}$$

Así, el estimador ML para Φ resulta:

$$\hat{\Phi} = \frac{1}{n} (GG^{\top})^{-1} GY^{\top} YG^{\top} (GG^{\top})^{-1}.$$



Finalmente, note que

$$\mathbf{G}^\top (\mathbf{G}\mathbf{G}^\top)^{-1} \mathbf{G} = \mathbf{I}_q - \mathbf{Z}^\top (\mathbf{Z}\mathbf{Z}^\top)^{-1} \mathbf{Z}.$$

Esto permite construir una matriz asociada a \mathbf{G} tal que $\mathbf{G}\mathbf{Z}^\top = \mathbf{0}$ y que además

$$\hat{\Sigma} = \mathbf{Z}^\top \hat{\Gamma} \mathbf{Z} + \mathbf{G}^\top \hat{\Phi} \mathbf{G}.$$

Basta apreciar que

$$\begin{aligned} \mathbf{G}^\top \hat{\Phi} \mathbf{G} &= \frac{1}{n} \mathbf{G}^\top (\mathbf{G}\mathbf{G}^\top)^{-1} \mathbf{G} \mathbf{Y}^\top \mathbf{Y} \mathbf{G}^\top (\mathbf{G}\mathbf{G}^\top)^{-1} \mathbf{G} \\ &= \frac{1}{n} (\mathbf{I}_q - \mathbf{Z}^\top (\mathbf{Z}\mathbf{Z}^\top)^{-1} \mathbf{Z}) \mathbf{Y}^\top \mathbf{Y} (\mathbf{I}_q - \mathbf{Z}^\top (\mathbf{Z}\mathbf{Z}^\top)^{-1} \mathbf{Z}). \end{aligned}$$



```
1 ## Supondremos que los datos 'x', 'y', 'z' estan cargados en
2 ## nuestro directorio de trabajo.
3
4 # calculos en el modelo de regresion multivariado
5 xy <- crossprod(x, y)
6 r <- y - x %*% solve(xx, xy)
7 S <- crossprod(r)
8
9 # Salida
10 S
11           [,1]      [,2]      [,3]      [,4]
12 [1,] 135.38636   67.92045   97.75568   67.75568
13 [2,]  67.92045 104.61932   73.17898   82.92898
14 [3,]  97.75568   73.17898 161.39347  103.26847
15 [4,]  67.75568   82.92898 103.26847 124.64347
```

Comandos en R

```
1 # contruye estimador para B
2 xx <- crossprod(x)
3 zz <- crossprod(t(z))
4 xyz <- crossprod(x, y %*% t(z))
5 B <- solve(xx, xyz %*% solve(zz))
6
7 # Salida
8 B
9           Intercept           age
10 Male      16.34063  0.7843750
11 Female    17.37273  0.4795455
12
13 # construye estimador para Gamma
14 zsz <- z %*% S %*% t(z)
15 Gamma <- solve(zz, zsz %*% solve(zz)) / n
16
17 # Salida
18 Gamma
19           [,1]      [,2]
20 [1,] 15.368997 -1.1421659
21 [2,] -1.142166  0.1095691
```



Comandos en R

```
1 p <- ncol(z)
2 res <- diag(p) - t(z) %*% solve(zz, z)
3 res
4      [,1] [,2] [,3] [,4]
5 [1,]  0.3 -0.4 -0.1  0.2
6 [2,] -0.4  0.7 -0.2 -0.1
7 [3,] -0.1 -0.2  0.7 -0.4
8 [4,]  0.2 -0.1 -0.4  0.3
9
10 yy <- crossprod(y)
11 gg <- res %*% yy %*% res /n
12 gg
13      [,1]      [,2]      [,3]      [,4]
14 [1,]  0.4084259 -0.66972222  0.1141667  0.14712963
15 [2,] -0.6697222  1.40500000 -0.8008333  0.06555556
16 [3,]  0.1141667 -0.80083333  1.2591667 -0.57250000
17 [4,]  0.1471296  0.06555556 -0.5725000  0.35981481
18
19 # construye estimador para Sigma
20 Sigma <- crossprod(z, Gamma %*% z) + gg
21
22 # Salida
23 Sigma
24      [,1]      [,2]      [,3]      [,4]
25 [1,]  4.515192  2.905818  3.158481  2.660218
26 [2,]  2.905818  4.887591  2.588808  3.362248
27 [3,]  3.158481  2.588808  4.994136  3.507796
28 [4,]  2.660218  3.362248  3.507796  5.223715
```



Observaciones:

- ▶ Soluciones **explícitas** (no iterativas) para estimadores ML y GLS.
- ▶ Tal resultado no es válido para **estructuras de covarianza más generales**.
- ▶ GMANOVA es útil solamente para datos **balanceados**



Considere el modelo

$$Y_{ij} = \mu + b_i + u_{ij}, \quad i = 1, \dots, p; j = 1, \dots, n,$$

donde $\{b_i\}$ son v.a independientes con $E(b_i) = \theta_i$, $\text{var}(b_i) = \psi^2$ y $\{u_{ij}\}$ son v.a. iid con media cero y varianza ϕ^2 .

Sea $\tilde{b}_i = b_i - \theta_i$ y $\epsilon_{ij} = b_i + u_{ij}$, luego

$$Y_{ij} = \mu + \theta_i + \epsilon_{ij}, \quad i = 1, \dots, p; j = 1, \dots, n.$$



El modelo anterior puede escribirse como

$$\mathbf{Y}_j = \mathbf{X}_j \boldsymbol{\beta} + \boldsymbol{\epsilon}_j, \quad j = 1, \dots, n,$$

donde $\mathbf{Y}_j = (Y_{1j}, \dots, Y_{pj})^T$, $\boldsymbol{\epsilon}_j = \tilde{b}_i \mathbf{1} + \mathbf{u}_j$, de este modo

$$E(\boldsymbol{\epsilon}_j) = \mathbf{0}, \quad \text{Cov}(\boldsymbol{\epsilon}_j) = \psi^2 \mathbf{1} \mathbf{1}^T + \phi^2 \mathbf{I}_p.$$



Sea $\mathbf{Y}_i = (Y_{i1}, \dots, Y_{im_i})^T$ vector aleatorio m_i -dimensional. Considere

$$\mathbf{Y}_i = \mathbf{X}_i \boldsymbol{\beta} + \boldsymbol{\epsilon}_i, \quad i = 1, \dots, n,$$

donde $\boldsymbol{\beta} \in \mathbb{R}^p$ es **común** para todos los individuos.

Supuesto distribucional:

$$\mathbf{Y}_i \stackrel{\text{ind}}{\sim} N_{m_i}(\mathbf{X}_i \boldsymbol{\beta}, \boldsymbol{\Sigma}_i(\boldsymbol{\tau})), \quad i = 1, \dots, n,$$

con $\boldsymbol{\tau} = (\tau_1, \dots, \tau_K)^T$.



Considere

$$\Sigma_i = \sigma^2 \mathbf{R}_i, \quad \mathbf{R}_i = \mathbf{R}_i(\boldsymbol{\lambda}).$$

La log-verosimilitud para $\boldsymbol{\theta} = (\boldsymbol{\beta}^T, \sigma^2, \boldsymbol{\lambda}^T)^T$ asume la forma

$$\begin{aligned} \ell(\boldsymbol{\theta}) = & -\frac{N}{2} \log 2\pi - \frac{N}{2} \log \sigma^2 \\ & - \frac{1}{2} \sum_{i=1}^n \left\{ \log |\mathbf{R}_i| + (\mathbf{Y}_i - \mathbf{X}_i \boldsymbol{\beta})^T \mathbf{R}_i^{-1} (\mathbf{Y}_i - \mathbf{X}_i \boldsymbol{\beta}) / \sigma^2 \right\}, \end{aligned}$$

donde $N = \sum_{i=1}^n m_i$.



Para λ fijo, los estimadores ML de β y σ^2 corresponden a GLS, esto es

$$\hat{\beta}(\lambda) = \left(\sum_{i=1}^n \mathbf{X}_i^T \mathbf{R}_i^{-1} \mathbf{X}_i \right)^{-1} \sum_{i=1}^n \mathbf{X}_i^T \mathbf{R}_i^{-1} \mathbf{Y}_i,$$
$$\hat{\sigma}^2(\lambda) = \frac{1}{N} \sum_{i=1}^n (\mathbf{Y}_i - \mathbf{X}_i \beta)^T \mathbf{R}_i^{-1} (\mathbf{Y}_i - \mathbf{X}_i \beta).$$

$\hat{\lambda}$ es obtenido maximizando la log-verosimilitud perfilada

$$\ell_*(\lambda) = c - \frac{1}{2} \sum_{i=1}^n \log |\mathbf{R}_i| - N \log \sum_{i=1}^n \|\mathbf{R}_i^{-1/2} (\mathbf{Y}_i - \mathbf{X}_i \hat{\beta}(\lambda))\|^2,$$

donde c representa una constante.



El cálculo de $\hat{\beta}(\lambda)$, $\sigma^2(\lambda)$ y $\hat{\lambda}$ puede ser amenizado si consideramos una **descomposición raíz cuadrada** (Cholesky, LDL) de R_i ,

$$R_i = L_i L_i^T, \quad L_i \text{ triangular inferior,}$$

y considere

$$\tilde{Y}_i = L_i^{-1} Y_i, \quad \tilde{X}_i = L_i^{-1} X_i,$$

En cuyo caso $\hat{\beta}(\lambda)$ y $\hat{\sigma}^2(\lambda)$ están dados por

$$\hat{\beta}(\lambda) = \left(\sum_{i=1}^n \tilde{X}_i^T \tilde{X}_i \right)^{-1} \sum_{i=1}^n \tilde{X}_i^T \tilde{Y}_i, \quad \hat{\sigma}^2(\lambda) = \frac{1}{N} \sum_{i=1}^n \|\tilde{Y}_i - \tilde{X}_i \hat{\beta}(\lambda)\|^2.$$



La función de log-verosimilitud perfilada puede ser evaluada como

$$\ell_*(\boldsymbol{\lambda}) = c - \sum_{i=1}^n \log |\mathbf{L}_i| - N \log \sum_{i=1}^n \|\tilde{\mathbf{Y}}_i - \tilde{\mathbf{X}}_i \hat{\boldsymbol{\beta}}(\boldsymbol{\lambda})\|^2.$$

Note que,

$$\sum_{i=1}^n \|\tilde{\mathbf{Y}}_i - \tilde{\mathbf{X}}_i \hat{\boldsymbol{\beta}}(\boldsymbol{\lambda})\|^2 = \|\tilde{\mathbf{Y}} - \tilde{\mathbf{X}} \hat{\boldsymbol{\beta}}(\boldsymbol{\lambda})\|^2$$

donde

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_n \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} \mathbf{Y}_1 \\ \vdots \\ \mathbf{Y}_n \end{pmatrix}.$$



Modelo:

$$Y_{ij} = \beta_0 + \beta_1 \text{Sexo} + \beta_2(\text{edad}_j - 11) + \beta_3(\text{edad}_j - 11)\text{Sexo} + \epsilon_{ij},$$

donde

$$\epsilon_i \stackrel{\text{ind}}{\sim} N_4(\mathbf{0}, \sigma^2 \mathbf{R}_i), \quad i = 1, \dots, 27,$$

con \mathbf{R}_i matriz **no estructurada**.



Gráfico con rectas ajustadas

