

MAT-468: Modelo no lineal con efectos mixtos

Felipe Osorio


fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Cinética de Teofilina (Boeckmann, Sheiner y Beal, 1984)

Dosis orales de droga anti-asmática Teofilina son suministradas a doce individuos, luego las concentraciones en la sangre (mg/L) son medidas en 11 instantes en un periodo de 25 horas.



Cinética de Teofilina (Boeckmann, Sheiner y Beal, 1984)

Observaciones:

- ▶ Estudio de laboratorio (**farmacocinética**) con pocos individuos y varias observaciones balanceadas.
- ▶ **Modelo mecánico:** **modelo de un compartimento** (primer orden) para expresar la concentración de Teofilina $C(t)$ en un instante t después de una **dosis inicial** Δ

$$C(t) = \frac{\Delta k_a}{V(k_a - Cl/V)} \left\{ \exp\left(-\frac{Cl}{V}t\right) - \exp(-k_a t) \right\},$$

donde k_a es la **tasa de absorción**, V representa el **volumen** de distribución y Cl es el **Clearance**

(es usual reparametrizar en términos de la **tasa de eliminación** $K = Cl/V$).

Objetivo:

- ▶ Determinar, basado en los perfiles observados, valores promedios de (k_a, V, Cl) para **realizar inferencias** en los individuos de la población.
- ▶ **Diseñar regímenes de dosificación** para mantener las concentraciones de la droga en los niveles deseados.



Etapa 1: Modelo sujeto-específico

Considere:

$$Y_{ij} = f(\mathbf{x}_{ij}, \boldsymbol{\phi}_i) + \epsilon_{ij}, \quad i = 1, \dots, n; j = 1, \dots, m_i, \quad (1)$$

donde Y_{ij} es la j -ésima observación del i -ésimo individuo, f es una función que gobierna el **comportamiento individual**, $\boldsymbol{\phi}_i$ es el vector de parámetros **sujeto específico** y \mathbf{x}_{ij} representa un **vector de covariables**.

En muchas aplicaciones $\mathbf{x}_{ij} = (t_{ij}, \mathbf{u}_i^T)^T$ donde t_{ij} es el **"tiempo"** y \mathbf{u}_i representa **condiciones adicionales**. (en nuestro *ejemplo de juguete*, $\mathbf{u}_i = \Delta_i$).



Etapa 2: Modelo poblacional

Sea

$$\phi_i = d(\mathbf{a}_i, \boldsymbol{\beta}, \mathbf{b}_i), \quad i = 1, \dots, n, \quad (2)$$

donde d es una función q -dimensional que depende del vector de efectos fijos $\boldsymbol{\beta}$, el vector de efectos aleatorios \mathbf{b}_i y covariables \mathbf{a}_i (asociadas a los atributos del individuo).

Caso especial:

$$\phi_i = \mathbf{A}_i \boldsymbol{\beta} + \mathbf{B}_i \mathbf{b}_i, \quad i = 1, \dots, n.$$



En nuestro ejemplo (Modelo poblacional):

Sea $\phi_i = (\log k_{ai}, \log V_i, \log Cl_i)^T$, $\mathbf{b}_i = (b_{i1}, b_{i2}, b_{i3})^T$ y considere

$$k_{ai} = \exp(\beta_1 + b_{i1}), \quad V_i = \exp(\beta_2 + b_{i2}), \quad Cl_i = \exp(\beta_3 + b_{i3}).$$

Este modelo **fuerza positividad** de los parámetros farmacocinéticos.



Sea $\mathbf{Y}_i = (Y_{i1}, \dots, Y_{im_i})^T$, $\boldsymbol{\epsilon}_i = (\epsilon_{i1}, \dots, \epsilon_{im_i})^T$ y

$$\mathbf{f}_i(\mathbf{z}_i, \boldsymbol{\phi}_i) = (f(\mathbf{x}_{i1}, \boldsymbol{\phi}_i), \dots, f(\mathbf{x}_{im_i}, \boldsymbol{\phi}_i))^T.$$

Supuesto distribucional:

Considere

$$\begin{aligned} \mathbf{Y}_i | \boldsymbol{\phi}_i &\stackrel{\text{ind}}{\sim} N_{m_i}(\mathbf{f}_i(\mathbf{z}_i, \boldsymbol{\phi}_i), \sigma^2 \mathbf{I}_{m_i}), \quad y \\ \boldsymbol{\phi}_i &= \mathbf{A}_i \boldsymbol{\beta} + \mathbf{b}_i, \quad \mathbf{b}_i \stackrel{\text{ind}}{\sim} N_q(\mathbf{0}, \boldsymbol{\Psi}), \end{aligned} \tag{3}$$

para $i = 1, \dots, n$, con $\boldsymbol{\Psi} = \boldsymbol{\Psi}(\boldsymbol{\theta})$



Modelo no lineal con efectos mixtos (Vonesh y Carter, 1992)

Vonesh y Carter (1992) desarrollaron un modelo mixto no lineal, pero **lineal** en los efectos aleatorios

$$Y_i = f(z_i, \beta) + Z_i(\beta)b_i + \epsilon_i, \quad i = 1, \dots, n,$$

donde Z_i es una matriz de rango completo de funciones conocidas que depende de los efectos fijos β . Además se asume que

$$b_i \stackrel{\text{ind}}{\sim} N(\mathbf{0}, \Psi), \quad \epsilon_i \stackrel{\text{ind}}{\sim} N(\mathbf{0}, \sigma^2 \mathbf{I}) \quad b_i \perp \epsilon_i$$

Nota:

Este enfoque se concentra **principalmente** en inferencias relacionadas a los efectos fijos.



Modelo no lineal con efectos mixtos

Estimación máximo verosímil en (3) se basa en la **distribución marginal** para la respuesta observada \mathbf{Y}

$$f(\mathbf{y}; \boldsymbol{\beta}, \sigma^2, \boldsymbol{\theta}) = \int_{\mathbb{R}^q} f(\mathbf{y}|\mathbf{b}; \boldsymbol{\beta}, \sigma^2) f(\mathbf{b}; \boldsymbol{\theta}) d\mathbf{b}.$$

Note que,

$$L(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2) = \frac{|\boldsymbol{\Delta}|^n}{(2\pi\sigma^2)^{(N+nq)/2}} \times \prod_{i=1}^n \int_{\mathbb{R}^q} \exp \left\{ -\frac{1}{2\sigma^2} (\|\mathbf{Y}_i - \mathbf{f}_i(\mathbf{z}_i, \mathbf{b}_i)\|^2 + \|\boldsymbol{\Delta}\mathbf{b}_i\|^2) \right\} d\mathbf{b}_i,$$

en general esta integral **no tiene solución explícita** cuando \mathbf{f} es no lineal en \mathbf{b}_i .



Algunos procedimientos de estimación:

- ▶ Aproximación de Laplace (Wolfinger, 1993; Vonesh, 1996; Pinheiro y Bates, 1995).
- ▶ Procedimientos de linealización (Lindstrom y Bates, 1990; Vonesh y Carter, 1992).
- ▶ Integración numérica (Pinheiro y Bates, 1995).
- ▶ Algoritmos MCEM (Walker, 1996) y SAEM (Kuhn y Lavielle, 2005).



Note que

$$L(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2; \mathbf{y}) = \prod_{i=1}^n L_i(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2; \mathbf{y}_i),$$

donde

$$L_i(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2; \mathbf{y}_i) = \int_{\mathbb{R}^q} (2\pi\sigma^2)^{-(n_i+q)/2} |\boldsymbol{\Delta}| \exp\{-g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \mathbf{b}_i)/2\sigma^2\} d\mathbf{b}_i$$

con

$$g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \mathbf{b}_i) = \|\mathbf{Y}_i - \mathbf{f}_i(\mathbf{z}_i, \mathbf{b}_i)\|^2 + \|\boldsymbol{\Delta}\mathbf{b}_i\|^2.$$



Usando la aproximación de Laplace en NLME

Sea

$$\hat{\mathbf{b}}_i = \hat{\mathbf{b}}_i(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i) = \arg \min_{\boldsymbol{\theta}} g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \mathbf{b}_i),$$

$$\dot{g}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \mathbf{b}_i) = \frac{\partial g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \mathbf{b}_i)}{\partial \mathbf{b}_i},$$

$$\ddot{g}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \mathbf{b}_i) = \frac{\partial^2 g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \mathbf{b}_i)}{\partial \mathbf{b}_i \partial \mathbf{b}_i^T},$$

y considere la expansión de Taylor de segundo orden

$$g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \mathbf{b}_i) \approx g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i) + \frac{1}{2}(\mathbf{b}_i - \hat{\mathbf{b}}_i)^T \ddot{g}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i)(\mathbf{b}_i - \hat{\mathbf{b}}_i).$$

Recuerde que $\dot{g}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i) = \mathbf{0}$.



Usando la aproximación de Laplace en NLME

La aproximación de Laplace es definida como

$$L(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2) = (2\pi\sigma^2)^{-\frac{N}{2}} |\boldsymbol{\Delta}|^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i) \right\} \\ \times \prod_{i=1}^n \int_{\mathbb{R}^q} (2\pi\sigma^2)^{\frac{q}{2}} \exp \left\{ -\frac{1}{2\sigma^2} (\mathbf{b}_i - \hat{\mathbf{b}}_i)^T \ddot{g}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i) (\mathbf{b}_i - \hat{\mathbf{b}}_i) \right\} d\mathbf{b}_i$$

esto es,

$$L(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2) = (2\pi\sigma^2)^{-\frac{N}{2}} |\boldsymbol{\Delta}|^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i) \right\} \\ \times \prod_{i=1}^n |\ddot{g}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i)|^{-\frac{1}{2}}.$$



Note que

$$\dot{g}(\beta, \theta, \mathbf{y}_i, \mathbf{b}_i) = -2 \frac{\partial \mathbf{f}_i(\mathbf{z}_i, \mathbf{b}_i)}{\partial \mathbf{b}_i} (\mathbf{Y}_i - \mathbf{f}_i(\mathbf{z}_i, \mathbf{b}_i)) + 2 \Delta^T \Delta \mathbf{b}_i$$

y podemos utilizar la siguiente iteración para obtener $\hat{\mathbf{b}}_i$:

$$\hat{\mathbf{b}}_i^{(r+1)} = (\Delta^T \Delta)^{-1} \frac{\partial \mathbf{f}_i(\mathbf{z}_i, \mathbf{b}_i)}{\partial \mathbf{b}_i} \Big|_{\mathbf{b}_i = \hat{\mathbf{b}}_i^{(r)}} (\mathbf{Y}_i - \mathbf{f}_i(\mathbf{z}_i, \hat{\mathbf{b}}_i^{(r)})).$$



Finalmente, considerando la siguiente aproximación para la matriz Hessiana

$$\ddot{g}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \mathbf{b}_i) \approx \mathbf{G}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i) = \frac{\partial \mathbf{f}_i(\mathbf{z}_i, \mathbf{b}_i)}{\partial \mathbf{b}_i^T} \Big|_{\mathbf{b}_i = \hat{\mathbf{b}}_i} \frac{\partial \mathbf{f}_i(\mathbf{z}_i, \mathbf{b}_i)}{\partial \mathbf{b}_i} \Big|_{\mathbf{b}_i = \hat{\mathbf{b}}_i} + \boldsymbol{\Delta}^T \boldsymbol{\Delta}.$$

Tenemos que la aproximación Laplace para la log-verosimilitud está dada por

$$\begin{aligned} \ell_{\text{Lapl}}(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2) = & -\frac{N}{2} \log(2\pi\sigma^2) + n \log |\boldsymbol{\Delta}| \\ & - \frac{1}{2} \left\{ \sum_{i=1}^n \log |\mathbf{G}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i)| + \sum_{i=1}^n g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i) / \sigma^2 \right\}. \end{aligned}$$



Note que $\hat{\mathbf{b}}_i$ no depende de σ^2 , para $\boldsymbol{\beta}$ y $\boldsymbol{\theta}$ fijados el MLE de σ^2 es

$$\hat{\sigma}^2 = \hat{\sigma}^2(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}) = \frac{1}{N} \sum_{i=1}^n g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i).$$

Perfilando $\ell_{\text{Lapl}}(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2)$ en $\hat{\sigma}^2$, obtenemos

$$\ell_{\text{Lapl}}^*(\boldsymbol{\beta}, \boldsymbol{\theta}) = -\frac{N}{2} [1 + \log(2\pi\hat{\sigma}^2)] + n \log |\boldsymbol{\Delta}| - \frac{1}{2} \sum_{i=1}^n \log |\mathbf{G}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i)|.$$



Aproximación de primer orden

Suponga el modelo en dos etapas

$$Y_i = f_i(z_i, \phi_i) + \epsilon_i, \quad \epsilon_i \stackrel{\text{ind}}{\sim} N_{m_i}(\mathbf{0}, \sigma^2 \mathbf{I}),$$

y

$$\phi_i = \mathbf{A}_i \boldsymbol{\beta} + \mathbf{b}_i, \quad \mathbf{b}_i \stackrel{\text{ind}}{\sim} N_q(\mathbf{0}, \boldsymbol{\Psi}),$$

para $i = 1, \dots, n$, con $\epsilon_i \perp \mathbf{b}_i$ y $\boldsymbol{\Psi} = \boldsymbol{\Psi}(\boldsymbol{\lambda})$.

Sea $\boldsymbol{\eta}_i(\phi_i) = f_i(z_i, \phi_i)$ y considere una **aproximación de Taylor de primer orden** de $\boldsymbol{\eta}_i$ en torno de \mathbf{b}_i^* ,

$$\boldsymbol{\eta}_i(\mathbf{A}_i \boldsymbol{\beta} + \mathbf{b}_i) \approx \boldsymbol{\eta}_i(\mathbf{A}_i \boldsymbol{\beta} + \mathbf{b}_i^*) + \left. \frac{\partial \boldsymbol{\eta}_i(\mathbf{A}_i \boldsymbol{\beta} + \mathbf{b}_i)}{\partial \mathbf{b}_i^T} \right|_{\mathbf{b}_i = \mathbf{b}_i^*} (\mathbf{b}_i - \mathbf{b}_i^*),$$

y defina¹

$$\mathbf{Z}_i(\boldsymbol{\beta}, \mathbf{b}_i^*) = \left. \frac{\partial \boldsymbol{\eta}_i(\phi_i)}{\partial \mathbf{b}_i^T} \right|_{\mathbf{b}_i = \mathbf{b}_i^*}.$$

¹en ocasiones sólo escribiremos $\mathbf{Z}_i^*(\boldsymbol{\beta})$.



Para la elección de \mathbf{b}_i^* en la expansión de Taylor, se ha propuesto:

- ▶ El valor **promedio** de los \mathbf{b}_i s, es decir, $E(\mathbf{b}_i) = \mathbf{0}$ (FO).
- ▶ Alguna estimación para \mathbf{b}_i , digamos la **esperanza condicional** de los efectos aleatorios $\hat{\mathbf{b}}_i$ (FOCE).

Otra alternativa:

- ▶ Expandir $\boldsymbol{\eta}(\mathbf{A}_i\boldsymbol{\beta} + \mathbf{b}_i)$ en torno de **ambos** $\hat{\boldsymbol{\beta}}$ y $\hat{\mathbf{b}}_i$ (Aproximación LME²)

²implementada en biblioteca nlme.

Aproximación de primer orden

Para cada una de las alternativas anteriores, se aproxima la distribución condicional de \mathbf{Y}_i como

$$\mathbf{Y}_i | \mathbf{b}_i \dot{\sim} N_{m_i}(\boldsymbol{\eta}_i(\mathbf{A}_i \boldsymbol{\beta} + \mathbf{b}_i^*) - \mathbf{Z}_i^* \mathbf{b}_i^* + \mathbf{Z}_i^* \mathbf{b}_i, \sigma^2 \mathbf{I}),$$

además $\mathbf{b}_i \sim N_q(\mathbf{0}, \boldsymbol{\Psi})$.

De este modo, tenemos la siguiente aproximación para la distribución marginal

$$\mathbf{Y}_i \dot{\sim} N_{m_i}(\boldsymbol{\eta}_i(\mathbf{A}_i \boldsymbol{\beta} + \mathbf{b}_i^*) - \mathbf{Z}_i^* \mathbf{b}_i^*, \sigma^2 \mathbf{V}_i^*),$$

donde

$$\mathbf{V}_i^* = \mathbf{Z}_i^* \mathbf{D} \mathbf{Z}_i^{*T} + \mathbf{I}, \quad \text{con } \boldsymbol{\Psi} = \sigma^2 \mathbf{D}.$$



Aproximación de primer orden

Para el **modelo poblacional**

$$\phi_i = d(a_i, \beta, b_i), \quad i = 1, \dots, n,$$

también podemos considerar una aproximación de primer orden,

$$\begin{aligned} d(a_i, \beta, b_i) &\approx d(a_i, \beta, b_i^*) + \left. \frac{\partial d(a_i, \beta, b_i)}{\partial b_i^T} \right|_{b_i=b_i^*} (b_i - b_i^*) \\ &= g_i^*(a_i, \beta) + B_i^*(\beta)(b_i - b_i^*) \end{aligned}$$

con

$$g_i^*(a_i, \beta) = d(a_i, \beta, b_i^*), \quad B_i^*(\beta) = \left. \frac{\partial d(a_i, \beta, b_i)}{\partial b_i^T} \right|_{b_i=b_i^*}$$



Cuando consideramos $\mathbf{b}_i^* = \mathbf{0}$ ($= E(\mathbf{b}_i)$) tenemos el modelo jerárquico

$$\begin{aligned}\mathbf{Y}_i | \mathbf{b}_i &\dot{\sim} N_{m_i}(\boldsymbol{\eta}_i(\boldsymbol{\beta}) + \mathbf{Z}_i(\boldsymbol{\beta})\mathbf{b}_i, \sigma^2 \mathbf{I}) \\ \mathbf{b}_i &\sim N_q(\mathbf{0}, \boldsymbol{\Psi}),\end{aligned}$$

con distribución marginal³.

$$\mathbf{Y}_i \dot{\sim} N_{m_i}(\boldsymbol{\eta}_i(\boldsymbol{\beta}), \mathbf{Z}_i(\boldsymbol{\beta})\boldsymbol{\Psi}\mathbf{Z}_i^T(\boldsymbol{\beta}) + \sigma^2 \mathbf{I}),$$

donde $\mathbf{Z}_i(\boldsymbol{\beta}) = \mathbf{Z}_i(\boldsymbol{\beta}, \mathbf{0})$.

La aproximación FO de la log-verosimilitud marginal está dada por

$$\begin{aligned}\ell_{\text{FO}}(\boldsymbol{\theta}) &= -\frac{1}{2} \left\{ N \log \sigma^2 + \sum_{i=1}^n \log |\mathbf{Z}_i(\boldsymbol{\beta}) \mathbf{D} \mathbf{Z}_i^T(\boldsymbol{\beta}) + \mathbf{I}| \right\} \\ &\quad - \frac{1}{2\sigma^2} \sum_{i=1}^n (\mathbf{Y}_i - \boldsymbol{\eta}_i(\boldsymbol{\beta}))^T (\mathbf{Z}_i(\boldsymbol{\beta}) \mathbf{D} \mathbf{Z}_i^T(\boldsymbol{\beta}) + \mathbf{I})^{-1} (\mathbf{Y}_i - \boldsymbol{\eta}_i(\boldsymbol{\beta})).\end{aligned}$$

y utilizamos lme para realizar la estimación de parámetros.

³compare con modelo de Vonesh y Carter (1992)

Considerando $\mathbf{b}_i^* = \hat{\mathbf{b}}_i$ ($= E(\mathbf{b}_i | \mathbf{Y}_i)$) tenemos el modelo jerárquico

$$\begin{aligned}\mathbf{Y}_i | \mathbf{b}_i &\sim N_{m_i}(\boldsymbol{\eta}_i(\boldsymbol{\beta}, \hat{\mathbf{b}}_i) - \hat{\mathbf{Z}}_i(\boldsymbol{\beta})\hat{\mathbf{b}}_i + \hat{\mathbf{Z}}_i(\boldsymbol{\beta})\mathbf{b}_i, \sigma^2 \mathbf{I}), \\ \mathbf{b}_i &\sim N_q(\mathbf{0}, \boldsymbol{\Psi}),\end{aligned}$$

en cuyo caso la distribución marginal asume la forma

$$\mathbf{Y}_i \sim N_{m_i}(\boldsymbol{\eta}_i(\boldsymbol{\beta}, \hat{\mathbf{b}}_i) - \hat{\mathbf{Z}}_i(\boldsymbol{\beta})\hat{\mathbf{b}}_i, \sigma^2 \hat{\mathbf{V}}_i(\boldsymbol{\beta})),$$

donde

$$\hat{\mathbf{V}}_i(\boldsymbol{\beta}) = \hat{\mathbf{Z}}_i(\boldsymbol{\beta}) \mathbf{D} \hat{\mathbf{Z}}_i^T(\boldsymbol{\beta}) + \mathbf{I},$$

con $\hat{\mathbf{Z}}_i(\boldsymbol{\beta}) = \mathbf{Z}_i(\boldsymbol{\beta}, \hat{\mathbf{b}}_i)$.



Sea

$$\hat{\mathbf{w}}_i(\boldsymbol{\beta}) = \mathbf{Y}_i - \boldsymbol{\eta}_i(\boldsymbol{\beta}, \hat{\mathbf{b}}_i) + \hat{\mathbf{Z}}_i(\boldsymbol{\beta})\hat{\mathbf{b}}_i,$$

luego, la aproximación FOCE para la log-verosimilitud marginal asume la forma

$$\begin{aligned} \ell_{\text{FOCE}}(\boldsymbol{\theta}) = & -\frac{1}{2} \left\{ N \log \sigma^2 + \sum_{i=1}^n \log |\hat{\mathbf{Z}}(\boldsymbol{\beta}) \mathbf{D} \hat{\mathbf{Z}}_i^T(\boldsymbol{\beta}) + \mathbf{I}| \right\} \\ & - \frac{1}{2\sigma^2} \sum_{i=1}^n (\hat{\mathbf{w}}_i - \hat{\mathbf{Z}}_i(\boldsymbol{\beta})\mathbf{b}_i)^T (\hat{\mathbf{Z}}(\boldsymbol{\beta}) \mathbf{D} \hat{\mathbf{Z}}_i^T(\boldsymbol{\beta}) + \mathbf{I})^{-1} (\hat{\mathbf{w}}_i - \hat{\mathbf{Z}}_i(\boldsymbol{\beta})\mathbf{b}_i). \end{aligned}$$

y utilizamos lme para realizar la estimación de parámetros.



Considere la siguiente aproximación de primer orden en torno de $\hat{\beta}$ y $\hat{\mathbf{b}}_i$,

$$\eta_i(\beta, \mathbf{b}_i) \approx \eta_i(\hat{\beta}, \hat{\mathbf{b}}_i) + \left(\frac{\partial \eta_i(\beta, \mathbf{b}_i)}{\partial \beta^T}, \frac{\partial \eta_i(\beta, \mathbf{b}_i)}{\partial \mathbf{b}_i^T} \right) \bigg|_{\beta=\hat{\beta}, \mathbf{b}_i=\hat{\mathbf{b}}_i} \begin{pmatrix} \beta - \hat{\beta} \\ \mathbf{b}_i - \hat{\mathbf{b}}_i \end{pmatrix}$$

defina

$$\widehat{\mathbf{X}}_i = \frac{\partial \eta_i(\beta, \mathbf{b}_i)}{\partial \beta^T} \bigg|_{\beta=\hat{\beta}, \mathbf{b}_i=\hat{\mathbf{b}}_i}, \quad \widehat{\mathbf{Z}}_i = \frac{\partial \eta_i(\beta, \mathbf{b}_i)}{\partial \mathbf{b}_i^T} \bigg|_{\beta=\hat{\beta}, \mathbf{b}_i=\hat{\mathbf{b}}_i},$$

de este modo, tenemos

$$\eta_i(\beta, \mathbf{b}_i) \approx \eta_i(\hat{\beta}, \hat{\mathbf{b}}_i) + \widehat{\mathbf{X}}_i(\beta - \hat{\beta}) + \widehat{\mathbf{Z}}_i(\mathbf{b}_i - \hat{\mathbf{b}}_i).$$



Usando la aproximación LME, tenemos el modelo jerárquico

$$\begin{aligned}Y_i | \mathbf{b}_i &\sim N_{m_i}(\boldsymbol{\eta}_i(\hat{\boldsymbol{\beta}}, \hat{\mathbf{b}}_i) - \widehat{\mathbf{X}}_i \hat{\boldsymbol{\beta}} - \widehat{\mathbf{Z}}_i \hat{\mathbf{b}}_i + \widehat{\mathbf{X}}_i \boldsymbol{\beta} + \widehat{\mathbf{Z}}_i \mathbf{b}_i, \sigma^2 \mathbf{I}), \\ \mathbf{b}_i &\sim N_q(\mathbf{0}, \boldsymbol{\Psi}),\end{aligned}$$

con distribución marginal (aproximada)

$$Y_i \sim N_{m_i}(\boldsymbol{\eta}_i(\hat{\boldsymbol{\beta}}, \hat{\mathbf{b}}_i) - \widehat{\mathbf{X}}_i \hat{\boldsymbol{\beta}} - \widehat{\mathbf{Z}}_i \hat{\mathbf{b}}_i + \widehat{\mathbf{X}}_i \boldsymbol{\beta}, \sigma^2 \widehat{\mathbf{V}}_i),$$

donde

$$\widehat{\mathbf{V}}_i = \widehat{\mathbf{Z}}_i \mathbf{D} \widehat{\mathbf{Z}}_i^T + \mathbf{I}.$$



$\hat{\beta}$ y $\hat{\mathbf{b}}_i$ son obtenidos por medio de resolver un problema de **mínimos cuadrados no lineal penalizado** (PNLS)

$$\min_{\beta, \mathbf{b}_i} \sum_{i=1}^n \left\{ \|\mathbf{Y}_i - \boldsymbol{\eta}_i(\beta, \mathbf{b}_i)\|^2 + \mathbf{b}_i \mathbf{D}^{-1} \mathbf{b}_i \right\},$$

y defina

$$\hat{\mathbf{w}}_i = \mathbf{Y}_i - \boldsymbol{\eta}_i(\hat{\beta}, \hat{\mathbf{b}}_i) + \hat{\mathbf{X}}_i \hat{\beta} + \hat{\mathbf{Z}}_i \hat{\mathbf{b}}_i,$$

para $i = 1, \dots, n$.



La aproximación LME para la log-verosimilitud marginal está dada por

$$\begin{aligned}\ell_{\text{LME}}(\boldsymbol{\theta}) = & -\frac{1}{2} \left\{ N \log \sigma^2 + \sum_{i=1}^n \log |\hat{\mathbf{Z}}_i \mathbf{D} \hat{\mathbf{Z}}_i^T + \mathbf{I}| \right\} \\ & - \frac{1}{2\sigma^2} \sum_{i=1}^n (\hat{\mathbf{w}}_i - \hat{\mathbf{X}}_i \boldsymbol{\beta})^T (\hat{\mathbf{Z}}_i \mathbf{D} \hat{\mathbf{Z}}_i^T + \mathbf{I})^{-1} (\hat{\mathbf{w}}_i - \hat{\mathbf{X}}_i \boldsymbol{\beta}).\end{aligned}$$

y se utiliza lme para estimar de parámetros de escala \mathbf{D} y σ^2 .




Observaciones:

- ▶ Opcionalmente también es posible actualizar las estimaciones $\hat{\beta}$ y \hat{b}_i en la etapa LME (Wolfinger, 1993).
- ▶ La estrategia anterior converge a los **mismos valores** que los obtenidos por el **algoritmo alternante** (PNLS-LME), aunque más lentamente.
- ▶ Wolfinger (1993) mostró que la aproximación LME para REML es equivalente a la aproximación de Laplace asumiendo una priori plana para β .



Cinética de Teofilina (Boeckmann, Sheiner y Beal, 1984)

Dosis orales de droga anti-asmática Teofilina son suministradas a doce individuos, luego las concentraciones en la sangre (mg/L) son medidas en 11 instantes en un periodo de 25 horas.



Modelo:

$$Y_{ij} = \frac{\Delta_i K_i k_{ai}}{Cl_i(k_{ai} - K_i)} \{ \exp(-K_i t_{ij}) - \exp(-k_{ai} t_{ij}) \}, \quad (4)$$

donde Δ_i representa la dosis inicial, k_{ai} y K_i son las constantes de absorción y eliminación, respectivamente y Cl_i es el Clearance, con

$$k_{ai} = \exp(\beta_1 + b_{i1}), \quad K_i = \exp(\beta_2 + b_{i2}), \quad Cl_i = \exp(\beta_3 + b_{i3}).$$

donde $\mathbf{b}_i = (b_{1i}, b_{2i}, b_{3i})^T \stackrel{\text{ind}}{\sim} N_3(\mathbf{0}, \Psi)$.



Cinética de Teofilina (ajuste individual)


Ajustando el modelo [sin considerar](#) los efectos aleatorios (usando función `nlsList`), tenemos

i	$\log \widehat{K}_i$	$\log \widehat{k}_{a_i}$	$\log \widehat{Cl}_i$
1	-2.920	0.575	-3.916
2	-2.286	0.664	-3.106
3	-2.508	0.898	-3.230
4	-2.436	0.158	-3.286
5	-2.425	0.386	-3.133
6	-2.307	0.152	-2.973
7	-2.280	-0.386	-2.964
8	-2.386	0.319	-3.069
9	-2.446	2.182	-3.421
10	-2.604	-0.363	-3.428
11	-2.322	1.348	-2.860
12	-2.248	-0.183	-3.170

además $\widehat{\sigma}^2 = 0.490$.



Cinética de Teofilina



Cinética de Teofilina (modelo nlme)

Realizando el ajuste del modelo en (4) (usando función nlme), tenemos


$$\hat{\beta} = (\hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3)^T = (0.451, -2.433, -3.214)^T, \quad \hat{\sigma}^2 = 0.465,$$
$$\hat{C} = \begin{pmatrix} 1.000 & 0.012 & 0.995 \\ 0.012 & 1.000 & -.089 \\ 0.995 & -.089 & 1.000 \end{pmatrix}, \quad \hat{V} = \text{diag}(0.131, 0.638, 0.251),$$

i	\hat{b}_{1i}	\hat{b}_{2i}	\hat{b}_{3i}	i	\hat{b}_{1i}	\hat{b}_{2i}	\hat{b}_{3i}
1	-0.289	0.038	-0.554	7	0.097	-0.777	0.217
2	0.023	0.284	0.034	8	0.078	-0.163	0.155
3	0.029	0.331	0.042	9	-0.113	1.501	-0.276
4	-0.055	-0.242	-0.095	10	-0.106	-0.831	-0.169
5	0.053	-0.098	0.105	11	0.220	0.699	0.393
6	0.108	-0.295	0.219	12	-0.046	-0.447	-0.070

donde $\hat{\Psi} = \hat{V}\hat{C}\hat{V}$. Además $\ell_{\text{LME}}(\hat{\theta}) = -173.321$ y $AIC = 366.641$.



Cinética de Teofilina



Considerando que $\mathbf{b}_i \sim N_3(\mathbf{0}, \Psi)$ con $\Psi = \text{diag}(\psi_1, \psi_2, \psi_3)$, obtenemos

$$\begin{aligned}\hat{\beta} &= (\hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3)^T = (0.465, -2.455, -3.227)^T, & \hat{\sigma}^2 &= 0.503, \\ \hat{\Psi} &= \text{diag}(\hat{\psi}_1, \hat{\psi}_2, \hat{\psi}_3) = \text{diag}(0.000, 0.644, 0.167),\end{aligned}$$

además $\ell_{\text{LME}}(\hat{\theta}) = -177.024$ y $AIC = 368.047$.

Por otro lado si consideramos el modelo poblacional

$$\log k_{a_i} = \beta_1 + b_{1i}, \quad \log Cl_i = \beta_3 + b_{2i}$$


con $\mathbf{b}_i \sim N_2(\mathbf{0}, \Psi)$ talque $\Psi = \text{diag}(\psi_1, \psi_2)$, obtenemos

$$\begin{aligned}\hat{\beta} &= (\hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3)^T = (0.466, -2.455, -3.227)^T, & \hat{\sigma}^2 &= 0.503, \\ \hat{\Psi} &= \text{diag}(\hat{\psi}_1, \hat{\psi}_2) = \text{diag}(0.644, 0.167),\end{aligned}$$

además $\ell_{\text{LME}}(\hat{\theta}) = -177.021$ y $AIC = 366.043$.



Cinética de Teofilina



Considere $h(t)$ función regular (uni-dimensional) y

$$g(t) = h(t)(2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{1}{2} \left(\frac{t-\mu}{\sigma} \right)^2 \right\}.$$

Cuadratura gaussiana utiliza la siguiente aproximación

$$\int_{\mathbb{R}} g(t) dt \approx \sum_{j=1}^M m_j g(z_j),$$

donde

$$m_j = w_j \exp(t_j^2) \sqrt{2}\sigma, \quad z_j = \mu + \sqrt{2}\sigma t_j.$$

Para implementar este enfoque, tablas de t_j , w_j y $w_j \exp(t_j^2)$ son requeridas (Naylor y Smith, 1982).



- ▶ Aproxima integrales con relación a un kernel fijado por un **promedio ponderado** del integrando evaluado en abscisas predeterminadas.
- ▶ Los pesos y abscisas usadas en la cuadratura Gaussiana para los kernels usuales pueden ser obtenidos desde **tablas** (Abramowitz y Stegun, 1964) o por un **algoritmo** propuesto por Golub (1973).
- ▶ Es bien conocido que las reglas para cuadratura Gaussiana en el caso de integrales múltiples es **numéricamente complejo** (curse of dimensionality).



Función de verosimilitud

Se desea aproximar la función de verosimilitud

$$L(\beta, \theta, \sigma^2) = \prod_{i=1}^n \int_{\mathbb{R}^q} (2\pi\sigma^2)^{-(n_i+q)/2} |\Delta| \exp\{-g(\beta, \theta, \mathbf{y}_i, \mathbf{b}_i)/2\sigma^2\} d\mathbf{b}_i$$

donde

$$g(\beta, \theta, \mathbf{y}_i, \mathbf{b}_i) = \|\mathbf{Y}_i - \mathbf{f}_i(\mathbf{z}_i, \mathbf{b}_i)\|^2 + \|\Delta \mathbf{b}_i\|^2.$$

Sea

$$\hat{\mathbf{b}}_i = \hat{\mathbf{b}}_i(\beta, \theta, \mathbf{y}_i) = \arg \min_{\theta} g(\beta, \theta, \mathbf{y}_i, \mathbf{b}_i),$$

$$\mathbf{G}(\beta, \theta, \mathbf{y}_i) = \frac{\partial^2 g(\beta, \theta, \mathbf{y}_i, \mathbf{b}_i)}{\partial \mathbf{b}_i \partial \mathbf{b}_i^T} \Big|_{\mathbf{b}_i = \hat{\mathbf{b}}_i}.$$

Por [Slide 13](#), tenemos que el integrando es (salvo una constante) aproximadamente igual a la densidad⁴.

$$N_q(\hat{\mathbf{b}}_i, \sigma^2 \mathbf{G}^{-1}(\beta, \theta, \mathbf{y}_i)).$$

⁴que es una elección natural para la distribución de importancia



Aproximación por importance sampling

Obtenemos una observación desde $N_q(\hat{\mathbf{b}}_i, \sigma^2 \mathbf{G}^{-1}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i))$, tomando $\mathbf{z}^* \sim N(\mathbf{0}, \mathbf{I})$ y calculando

$$\mathbf{b}_i^* = \hat{\mathbf{b}}_i + \sigma \mathbf{G}^{-1/2}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i) \mathbf{z}^*,$$

donde $\mathbf{G}^{1/2}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i)$ es el factor Cholesky de $\mathbf{G}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i)$.

Repetimos el procedimiento anterior M veces (número de muestras de importancia).

La aproximación importance sampling de la log-verosimilitud marginal está dada por

$$\begin{aligned} \ell_{\text{IS}}(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2) = & -\frac{1}{2} \left\{ N \log(2\pi\sigma^2) + n \log |\mathbf{D}| + \sum_{i=1}^n \log |\mathbf{G}(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2)| \right\} \\ & + \sum_{i=1}^n \log \left\{ \sum_{j=1}^M \exp[-g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \mathbf{b}_{ij}^*)/2\sigma^2 + \|\mathbf{z}_j^*\|^2/2]/M \right\}. \end{aligned}$$

En este caso no es posible obtener expresiones en forma cerrada del MLE de σ^2 para $\boldsymbol{\beta}$ y $\boldsymbol{\theta}$ fijos.



Idea:

Aprovechar la **estructura del integrando** en nlme para transformar el problema en la **aplicación sucesiva** de reglas de cuadratura Gaussiana unidimensionales.

Sean z_j^* , w_j , $j = 1, \dots, M$, las abscisas y los pesos para la cuadratura Gaussiana (unidimensional) con M puntos basados en un kernel $N(0, 1)$. Entonces

$$\begin{aligned} & \int_{\mathbb{R}^q} (2\pi\sigma^2)^{-q/2} |\mathbf{D}|^{-1/2} \exp\{-\|\mathbf{y}_i - \mathbf{f}_i(\boldsymbol{\beta}, \mathbf{b}_i)\|^2/2\sigma^2\} \exp(-\mathbf{b}_i^T \mathbf{D}^{-1} \mathbf{b}_i/2\sigma^2) d\mathbf{b}_i \\ &= \int_{\mathbb{R}^q} (2\pi)^{-q/2} \exp\{-\|\mathbf{y}_i - \mathbf{f}_i(\boldsymbol{\beta}, \sigma \mathbf{D}^{T/2} \mathbf{z}^*)\|^2/2\sigma^2\} \exp(-\|\mathbf{z}^*\|^2/2) d\mathbf{z}^* \\ &\approx \sum_{j_1=1}^M \cdots \sum_{j_q=1}^M \exp\{-\|\mathbf{y}_i - \mathbf{f}_i(\boldsymbol{\beta}, \sigma \mathbf{D}^{T/2} \mathbf{z}_{j_1, \dots, j_q}^*)\|^2/2\sigma^2\} \prod_{k=1}^q w_{j_k} \end{aligned}$$



Luego, la aproximación para la función de log-verosimilitud usando cuadratura Gaussiana está dada por

$$\begin{aligned}\ell_{\text{GQ}}(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2) = & -\frac{N}{2} \log(2\pi\sigma^2) \\ & + \sum_{i=1}^n \log \left\{ \sum_{\boldsymbol{j}}^M \exp(-\|\boldsymbol{y}_i - \boldsymbol{f}_i(\boldsymbol{\beta}, \sigma \boldsymbol{D}^{T/2} \boldsymbol{z}_{\boldsymbol{j}}^*)\|^2 / 2\sigma^2) \prod_{k=1}^q w_{j_k} \right\}\end{aligned}$$

donde $\boldsymbol{j} = (j_1, \dots, j_q)^T$.



Observaciones:

- ▶ Cuadratura Gaussiana corresponde a una **versión determinista** de integración Monte Carlo, donde las muestras de \mathbf{b}_i son generadas desde $N_q(\mathbf{0}, \sigma^2 \mathbf{D})$.
- ▶ **Cuadratura Gaussiana adaptativa** (AGQ) es el homólogo determinista de Importance sampling.
- ▶ En AGQ, la grilla de abscisas en la escala \mathbf{b}_i está centrada en $\hat{\mathbf{b}}_i$ y $G(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i)$ se utiliza para escalar \mathbf{z}^* .



Aproximación por cuadratura Gaussiana adaptativa

La cuadratura Gaussiana adaptativa está dada por

$$\begin{aligned} & \int_{\mathbb{R}^q} (2\pi\sigma^2)^{-q/2} |\mathbf{D}|^{-1/2} \exp\{-\|\mathbf{y}_i - \mathbf{f}_i(\boldsymbol{\beta}, \mathbf{b}_i)\|^2/2\sigma^2\} \exp(-\mathbf{b}_i^T \mathbf{D}^{-1} \mathbf{b}_i/2\sigma^2) d\mathbf{b}_i \\ &= \int_{\mathbb{R}^q} (2\pi)^{-q/2} |\mathbf{G}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i) \mathbf{D}|^{-1/2} \\ &\times \exp\{-g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i + \sigma \mathbf{G}^{-1/2}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i) \mathbf{z}^*)/2\sigma^2 + \|\mathbf{z}^*\|^2/2\} \exp(-\|\mathbf{z}^*\|^2/2) d\mathbf{z}^* \\ &\approx \sum_{j_1=1}^M \cdots \sum_{j_q=1}^M \exp\{-g(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i, \hat{\mathbf{b}}_i + \sigma \mathbf{G}^{-1/2}(\boldsymbol{\beta}, \boldsymbol{\theta}, \mathbf{y}_i) \mathbf{z}_{j_1, \dots, j_q}^*)/2\sigma^2 \\ &+ \|\mathbf{z}_{j_1, \dots, j_q}^*\|^2/2\} \prod_{k=1}^q w_{j_k}. \end{aligned}$$



La aproximación de la log-verosimilitud asume la forma

$$\begin{aligned}\ell_{\text{AGQ}}(\boldsymbol{\beta}, \boldsymbol{\theta}, \sigma^2) = & -\frac{1}{2} \left\{ N \log(2\pi\sigma^2) + n \log |\boldsymbol{D}| + \sum_{i=1}^n \log |\boldsymbol{G}(\boldsymbol{\beta}, \boldsymbol{\theta}, \boldsymbol{y}_i)| \right\} \\ & + \sum_{i=1}^n \log \left\{ \sum_{\boldsymbol{j}}^M \exp \{ -g(\boldsymbol{\beta}, \boldsymbol{\theta}, \boldsymbol{y}_i, \hat{\boldsymbol{b}}_i + \sigma \boldsymbol{G}^{-1/2}(\boldsymbol{\beta}, \boldsymbol{\theta}, \boldsymbol{y}_i) \boldsymbol{z}_{\boldsymbol{j}}^*) / 2\sigma^2 + \|\boldsymbol{z}_{\boldsymbol{j}}^*\|^2 \} \prod_{k=1}^q w_{j_k} \right\}\end{aligned}$$

donde $\boldsymbol{j} = (j_1, \dots, j_q)^T$.




Observaciones:

- ▶ AGQ usa abscisas y pesos **fijos**, mientras que Importance sampling las determina por medio de simulación.
- ▶ Cuando $M = 1$ cuadratura Gaussiana adaptativa reduce a la aproximación Laplace.
- ▶ AGQ es **exacto** cuando f es lineal en b_i , esto no es verdad para cuadratura Gaussiana.



Cinética de Teofilina

Dosis orales de droga anti-asmática Teofilina son suministradas a doce individuos, luego las concentraciones en la sangre (mg/L) son medidas en 11 instantes en un periodo de 25 horas.



Modelo:

$$Y_{ij} = \frac{\Delta_i K k_{ai}}{Cl_i (k_{ai} - K)} \{ \exp(-K t_{ij}) - \exp(-k_{ai} t_{ij}) \},$$

donde Δ_i representa la dosis inicial, k_{ai} y K son las constantes de absorción y eliminación, respectivamente y Cl_i es el Clearance, con

$$Cl_i = \exp(\beta_1 + b_{i1}), \quad k_{ai} = \exp(\beta_2 + b_{i2}), \quad K = \exp(\beta_3).$$

donde $\mathbf{b}_i = (b_{1i}, b_{2i})^T \stackrel{\text{ind}}{\sim} N_2(\mathbf{0}, \Psi)$.



Cinética de Teofilina (Pinheiro y Bates, 1995)

Resultados de estimación:

Aproximación	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_3$	$\log \hat{\sigma}^2$	ℓ
LME	-3.22719	0.46548	-2.45464	-0.68660	-177.0237
Laplace	-3.22946	0.46876	-2.46432	-0.68658	-176.9995
Imp. sampling ₁₀₀₀	-3.22682	0.47614	-2.45851	-0.68747	-177.7689
Gaussiana ₅	-3.30411	0.50046	-2.48743	-0.48395	-182.4680
Gaussiana ₁₀	-3.23814	0.59525	-2.46872	-0.70276	-176.1008
Gaussiana ₁₀₀	-3.22684	0.47947	-2.45893	-0.68539	-177.7293
Gaussiana Adap. ₅	-3.22503	0.47566	-2.45788	-0.68677	-177.7499
Gaussiana Adap. ₁₀	-3.22705	0.47377	-2.45942	-0.68533	-177.7473



Número de evaluaciones funcionales hasta convergencia:

Aproximación	Evaluaciones funcionales
LME	1.512
Laplace	7.683
Gaussiana Adap. ₅	30.020
Gaussiana Adap. ₁₀	96.784
Gaussiana ₅	47.700
Gaussiana ₁₀	318.000
Gaussiana ₁₀₀	10.200.000
Imp. sampling ₁₀₀₀	11.211.284

